Риманов лес: ансамбли касательных классификаторов на случайных подмножествах каналов для переноса между испытуемыми

Д. Д. Дорин*

Аннотация. Ансамбли касательных классификаторов, обученных на подмножествах каналов и испытуемых обучающей выборки, побеждали в соревнованиях по интерфейсам мозг — компьютер, но теории таких ансамблей нет. Такой ансамбль назовем римановым лесом. Каждый его член, по аналогии со случайным лесом называемый деревом, получает случайную частотную полосу, случайное подмножество каналов и бутстреп-выборку испытуемых, перецентрирует главные подматрицы ковариаций относительно опорной точки сессии и обучает логистическую регрессию на их касательных признаках; лес усредняет вероятности классов. Доказано, что переход к отбеленной подматрице дерева не увеличивает ни геодезических расстояний, ни спектрального разброса, поэтому доказанные ранее явные оценки для касательных признаков выполняются для каждого дерева. Превышение квадратичного риска конечного леса над риском бесконечного равно средней дисперсии деревьев, деленной на их число. Доля касательных координат, общих для двух деревьев, найдена в явном виде. При сильной регуляризации и сбалансированных данных лес в первом приближении совпадает с одной логистической регрессией, которая штрафует связи между каналами сильнее, чем мощности каналов, а в изотропной модели корреляция двух деревьев равна доле общих координат. Внебутстреповая ошибка по испытуемым без переобучения оценивает ошибку на новом испытуемом. Из результатов следуют правила выбора размера подмножества и числа деревьев. Синтетический эксперимент подтверждает предсказанные корреляцию деревьев и дисперсию леса, а на открытых записях электроэнцефалограммы лес в среднем точнее одного касательного классификатора, хотя разница сопоставима со стандартным отклонением по испытуемым.

Ключевые слова: симметричные положительно определенные матрицы; касательное пространство; случайный лес; метод случайных подпространств; бэггинг; интерфейс мозг — компьютер; перенос между испытуемыми

*Московский физико-технический институт, dorin.dd@phystech.edu

1 Введение

Интерфейс мозг — компьютер распознает мысленные команды по многоканальной записи электроэнцефалограммы, или ЭЭГ. Записи разных людей различаются положением электродов, импедансом, анатомией и психофизиологическим состоянием, поэтому классификатор, обученный на одних испытуемых, на новом испытуемом без калибровки работает существенно хуже [1, 2]. Испытуемых в обучающей выборке при этом мало: в открытых наборах их от нескольких до нескольких десятков, так что распределение, на котором модель должна работать, представлено лишь несколькими независимыми образцами.

Методы на основе римановой геометрии ковариационных матриц [3–6] остаются одними из сильнейших в декодировании ЭЭГ [7, 8]. В этих методах ковариация окна сигнала проецируется на касательное пространство многообразия симметричных положительно определенных матриц в опорной точке, и координаты проекции, называемые касательными признаками, подаются в линейный классификатор; такой классификатор будем называть касательным. Для переноса между сессиями и испытуемыми ковариации каждой сессии перецентрируют [9]: опорная точка сессии переводится в единичную матрицу. Свойства касательной проекции доказаны с явными константами в [10]: признаки инвариантны к смешиванию каналов с точностью до поворота, искажение расстояний ограничено множителем, зависящим от спектрального разброса касательных векторов, то есть от разности их наибольшего и наименьшего собственных значений, а шум ковариации, оцененной по $\mathcal{T}$ отсчетам h каналов, имеет в признаках порядок $h/\sqrt{\mathcal{T}}$.

На практике касательный классификатор усиливают ансамблированием. Победные решения нескольких соревнований по анализу ЭЭГ и электрокортикограммы [11, 12] объединяли касательные классификаторы, построенные на отобранных подмножествах каналов, на частотных полосах и на случайных подмножествах испытуемых обучающей выборки. Теории таких ансамблей нет: неизвестно, как подмножество каналов меняет геометрию касательных признаков, как ошибка зависит от числа членов ансамбля и размера подмножества и что оценивает ошибка на испытуемых, не попавших в бутстреп-выборку члена ансамбля.

В работе рассматривается ансамбль, члены которого по аналогии со случайным лесом [13] называются деревьями, хотя каждый из них есть регуляризованная логистическая регрессия, а не дерево решений. Каждое дерево получает случайную частотную полосу, случайное подмножество из m каналов и бутстреп-выборку испытуемых, то есть выборку n испытуемых с возвращением. Дерево вычисляет касательные признаки перецентрированной главной подматрицы ковариации, составленной из строк и столбцов выбранных каналов, а лес усредняет вероятности классов деревьев. Предложение 1 показывает, что дерево видит сжатие отбеленной ковариации всех каналов на m-мерное подпространство; переход к нему не увеличивает ни геодезических расстояний, ни спектрального разброса, поэтому оценки [10] выполняются для каждого дерева с m каналами вместо h.

Теорема 1 выражает в явном виде избыточный риск леса из K деревьев и дает

экспоненциальную по K оценку вероятности того, что его ответ отличается от ответа бесконечного леса, то есть предела при $K \to \infty$. Теорема 2 дает ожидаемую долю касательных координат, общих для двух деревьев, и распределение числа деревьев, содержащих данную связь между каналами. Теорема 3 объясняет, как случайные подмножества каналов действуют в роли регуляризации. При сильной регуляризации дерево сводится к взвешенной разности средних классов, а лес при условиях теоремы в первом приближении по обратному коэффициенту регуляризации совпадает с одной логистической регрессией на всех каналах. Штраф этой регрессии на веса связей между каналами, то есть внедиагональных касательных координат, в $(h-1)/(m-1)$ раз больше штрафа на веса мощностей каналов, то есть диагональных координат. Если шум признаков изотропен, корреляция двух деревьев равна доле общих координат, и часть дисперсии леса, вызванная выбором подмножеств каналов, выражается явно через m и K. По предложению 2 внебутстреповая ошибка на испытуемом, вычисленная только по деревьям, в бутстреп-выборку которых он не попал, несмещенно оценивает ошибку на новом испытуемом леса, обученного без него; переобучать лес не нужно. Из результатов выведены правила выбора m и K.

Вычислительный эксперимент на синтетических данных проверяет предсказания теорем 2 и 3, а эксперимент на открытом наборе ЭЭГ соревнования Neural Interface Foundation Challenge на конференции NeurIPS 2026 показывает, что лес в среднем точнее одного касательного классификатора на новых испытуемых. Раздел 2 содержит обзор литературы, раздел 3 — конструкцию леса, раздел 4 — результаты, раздел 5 — эксперимент; доказательства вынесены в приложение.

2 Сопутствующие работы

Римановы методы в интерфейсах мозг — компьютер. Классификация ковариаций ЭЭГ в аффинно-инвариантной метрике предложена в [3] вместе с классификатором по минимальному расстоянию до римановых средних классов. Проекция на касательное пространство в точке риманова среднего с последующим линейным классификатором предложена в [4] и лежит в основе каждого дерева леса. Пространственные фильтры и ядра на основе этой геометрии предложены в [14–16]. Отбор электродов по риманову расстоянию между средними классов, вычисленному на главных подматрицах ковариации, предложен в [17]; это детерминированный аналог случайного выбора подматриц в лесу. Онлайн-варианты с адаптивными и рекурсивно обновляемыми средними развиты в [18–20]. Обзоры этого направления даны в [5–7], сравнения на открытых наборах — в [8, 21], а эталонная реализация содержится в библиотеке pyRiemann [22].

Перенос между сессиями и испытуемыми. Перецентрирование ковариаций каждой сессии или испытуемого к единичной матрице предложено в [9]. Риманов анализ Прокруста [23] добавляет выравнивание рассеяния и поворот, евклидово выравнивание [24] применяет ту же идею к сигналам, а параллельный перенос [25] и вы-

равнивание в касательном пространстве [26] обобщают ее. Онлайн-перецентрирование с рекурсивно обновляемой опорной точкой без меток рассмотрено в [27]; обзор методов переноса приведен в [2]. Ансамбль фильтров и классификаторов, обученных на отдельных испытуемых, для классификации без калибровки на новом испытуемом предложен в [28]. Ни одна из этих работ не рассматривает ансамбли на главных подматрицах ковариации.

Теория ансамблей. Бэггинг [29], метод случайных подпространств [30] и случайный лес [13] уменьшают дисперсию предсказаний за счет усреднения слабо коррелированных членов. Оценка ошибки леса через силу и корреляцию деревьев дана в [13], разложение дисперсии среднего коррелированных деревьев — в [31], разложение по неоднозначности и разложение на смещение, дисперсию и ковариацию — в [32, 33]. Зависимость ошибки от числа деревьев изучена в [34, 35]. В [36, 37] показано, что рандомизация признаков действует на линейные модели как неявная регуляризация, а в [38] построены ансамбли классификаторов на случайных проекциях с оценками ошибки; теорема 3 есть утверждение того же рода для главных подматриц ковариации, в котором структура регуляризации задается вероятностями включения пар каналов. Внебутстреповая оценка ошибки предложена в [39]; для сгруппированных данных бутстреп групп и соответствующая внебутстреповая оценка рассмотрены в [40], а необходимость кросс-валидации по испытуемым показана в [41].

Ансамбли в декодировании ЭЭГ. Ансамбль на случайных подмножествах электродов предложен в [42] для признаков, не связанных с ковариациями. Известны также ансамбли линейных классификаторов с отбором каналов [43], банки фильтров [44], ансамбли локальных пространственных фильтров [45], ансамбли римановых классификаторов по оценкам функциональной связности [46], по подмножествам каналов, проб и частот [47] и по временным подокнам [48], а также ансамбли по подмножествам электродов для обнаружения артефактов [49]. Ближе всего к лесу победные решения соревнований. В решении [11] соревнования по переносу между испытуемыми касательные классификаторы с отобранными электродами обучались на случайных подмножествах испытуемых обучающей выборки, выбранных без возвращения, и усреднялись; само сочетание подвыборки испытуемых, главных подматриц ковариации, касательных признаков и линейного классификатора, таким образом, не ново. В [12] касательные классификаторы одного испытуемого с отобранными электродами усреднялись по частотным полосам, а в [50] случайные подмножества испытуемых использовались на втором уровне ансамбля. В этих решениях подмножество каналов выбирается по критерию разделимости, члены ансамбля не перецентрируют признаки, и теоретического анализа не приводится. Обучаемое понижение размерности симметричных положительно определенных матриц вида $\mathbf{W}^\top\mathbf{C}\mathbf{W}$, частным случаем которого является взятие подматрицы, рассмотрено в [51]. От этих решений лес отличается равновероятным выбором подмножеств каналов и перецентрированием подматриц внутри деревьев; основное же содержание работы составляют доказанные

ниже свойства такого ансамбля.

3 Постановка и конструкция леса

Объекты и ковариации. Объектом служит окно многоканального сигнала из h каналов и $\mathcal{T}$ отсчетов, записанное после центрирования по времени в матрицу $\mathbf{X} \in \mathbb{R}^{h\times\mathcal{T}}$. Обучающая выборка содержит N окон; они сгруппированы по испытуемым $s = 1, \dots, n$ и сессиям, а внутри сессии упорядочены по времени. Каждое окно фильтруется B полосовыми фильтрами, и в полосе b ему сопоставляется ковариационная матрица $\mathbf{R}^{(b)} = (\mathcal{T}-1)^{-1}\mathbf{X}^{(b)}\mathbf{X}^{(b)\top}$. До теоремы 3 полоса фиксирована, и верхний индекс опускается. Окно имеет метку $y \in \{1, \dots, L\}$, где L — число классов, а $\mathbf{e}_c$ обозначает c-й единичный вектор.

Риманова структура. Множество $\mathbb{S}_+^h$ симметричных положительно определенных матриц размера $h \times h$ есть открытое подмножество пространства $\mathrm{Sym}(h)$ симметричных матриц. Как и в [10], оно снабжено аффинно-инвариантной метрикой

$$\langle \mathbf{V}, \mathbf{Z} \rangle_{\mathbf{R}} = \operatorname{tr}\left(\mathbf{R}^{-1}\mathbf{V}\mathbf{R}^{-1}\mathbf{Z}\right)$$

и образует риманово многообразие $\mathcal{R}$, касательное пространство которого в каждой точке есть $\mathrm{Sym}(h)$. Геодезическое расстояние равно

$$\delta_{\mathcal{R}}(\mathbf{R}_1, \mathbf{R}_2) = \left\| \log\left(\mathbf{R}_1^{-1/2}\mathbf{R}_2\mathbf{R}_1^{-1/2}\right)\right\|_F, \tag{1}$$

где матричные функции понимаются спектрально. Риманово среднее $\bar{\mathbf{R}}$ набора матриц $\mathbf{R}_1, \dots, \mathbf{R}_t$ минимизирует сумму квадратов геодезических расстояний до них; оно существует, единственно и характеризуется равенством [10]

$$\bar{\mathbf{R}} = \operatorname*{arg\,min}_{\mathbf{R}\in\mathbb{S}_+^h} \sum_{i=1}^{t} \delta_{\mathcal{R}}^2(\mathbf{R}, \mathbf{R}_i), \qquad \sum_{i=1}^{t} \log\left(\bar{\mathbf{R}}^{-1/2}\mathbf{R}_i\bar{\mathbf{R}}^{-1/2}\right) = \mathbf{0}.$$

Лог-евклидово среднее есть $\exp\left(t^{-1}\sum_i \log \mathbf{R}_i\right)$ [52]; в отличие от риманова, его можно обновлять с каждым новым окном по простой рекуррентной формуле.

Перецентрирование и касательные признаки. Ковариации разных сессий сдвинуты друг относительно друга на многообразии, прежде всего из-за различий испытуемых и контактов электродов. Перецентрирование относительно опорной точки $\mathbf{M}$ сессии есть отображение $\mathbf{R} \mapsto \mathbf{C} = \mathbf{M}^{-1/2}\mathbf{R}\mathbf{M}^{-1/2}$; оно переводит $\mathbf{M}$ в единичную матрицу, так что окна всех сессий сравниваются в одной точке [9]. Матрица $\mathbf{C}$ называется отбеленной ковариацией. Касательные признаки окна суть $\mathbf{x} = \mathrm{vec}_{\sqrt{2}} \log \mathbf{C} \in \mathbb{R}^d$, $d = h(h+1)/2$, где $\mathrm{vec}_{\sqrt{2}}$ записывает верхний треугольник симметричной матрицы в вектор с множителем $\sqrt{2}$ при внедиагональных элементах. Это координаты проекции

$\mathbf{R}$ на касательное пространство в точке $\mathbf{M}$ в базисе, ортонормированном относительно метрики, и $\|\mathbf{x}\|_2 = \delta_{\mathcal{R}}(\mathbf{M}, \mathbf{R})$ [10]; по лемме 2 работы [10] отображение $\mathrm{vec}_{\sqrt{2}}$ есть линейная изометрия $(\mathrm{Sym}(h), \|\cdot\|_F)$ на $(\mathbb{R}^d, \|\cdot\|_2)$. Координата вектора $\mathbf{x}$, отвечающая паре (k,k), описывает мощность канала k, а координата пары (k,l), $k<l$, — связь между каналами k и l; при $\mathbf{C}$, близкой к единичной, они близки к $\log C_{kk}$ и $\sqrt{2}\,C_{kl}$. Спектральный разброс симметричной матрицы $\mathbf{S}$ есть $\omega(\mathbf{S}) = \lambda_{\max}(\mathbf{S}) - \lambda_{\min}(\mathbf{S})$.

Опорная точка сессии. В пакетном режиме $\mathbf{M}$ есть риманово среднее ковариаций сессии. В потоковом режиме окна сессии поступают по одному, и опорная точка может зависеть лишь от уже поступивших окон. Тогда используется бегущее лог-евклидово среднее $\mathbf{M}_t = \exp \mathbf{L}_t$ окон $1, \ldots, t$ сессии с априорной точкой:

$$\mathbf{L}_t = \frac{w_0 \mathbf{L}_0 + \sum_{i=1}^{t} \log \mathbf{R}_i}{w_0 + t}. \tag{2}$$

Здесь $\mathbf{L}_0$ — среднее логарифмов ковариаций обучающей выборки, так что $\exp \mathbf{L}_0$ есть их лог-евклидово среднее и служит априорной опорной точкой. Вес априорной точки $w_0 \geqslant 0$ измеряется в окнах и стабилизирует опорную точку на первых окнах сессии.

Дерево. Для подмножества каналов $S \subset \{1, \ldots, h\}$ из m элементов через $\mathbf{E}_S \in \mathbb{R}^{h \times m}$ обозначена матрица из столбцов единичной матрицы с номерами из S. Для любой матрицы $\mathbf{Z}$ размера $h \times h$ главная подматрица есть $\mathbf{Z}_S = \mathbf{E}_S^{\top} \mathbf{Z} \mathbf{E}_S$; в частности, $\mathbf{R}_S$ принадлежит множеству $\mathbb{S}_+^m$ симметричных положительно определенных матриц размера $m \times m$. Дерево задается случайным параметром $\boldsymbol{\theta} = (b, S, \boldsymbol{\beta})$ с тремя независимыми компонентами: полоса b равновероятна среди B полос, подмножество S равновероятно среди всех подмножеств из m элементов, а вектор $\boldsymbol{\beta} = (\beta_1, \ldots, \beta_n)$ кратностей бутстреп-выборки испытуемых, то есть чисел повторений каждого испытуемого, имеет полиномиальное распределение с n испытаниями и равными вероятностями. Параметр принимает конечное число значений, поэтому средние по нему суть конечные суммы. Дерево перецентрирует главную подматрицу ковариации относительно главной подматрицы опорной точки; признаки дерева строятся по отбеленной подматрице $\mathbf{M}_S^{-1/2} \mathbf{R}_S \mathbf{M}_S^{-1/2}$:

$$\boldsymbol{\Lambda}_S = \log\left(\mathbf{M}_S^{-1/2} \mathbf{R}_S \mathbf{M}_S^{-1/2}\right) \in \mathrm{Sym}(m), \qquad \mathbf{x}_S = \mathrm{vec}_{\sqrt{2}}\, \boldsymbol{\Lambda}_S \in \mathbb{R}^{d_m}, \tag{3}$$

где $d_m = m(m+1)/2$. Классификатор дерева есть L_2-регуляризованная многоклассовая логистическая регрессия; бутстреп-выборка испытуемых входит в нее через веса окон, пропорциональные кратностям их испытуемых:

$$J_{\boldsymbol{\theta}}(\mathbf{W}, \mathbf{b}) = \sum_{i=1}^{N} a_i\, \ell\big(y_i, \mathbf{W}\mathbf{x}_{i,S} + \mathbf{b}\big) + \lambda \|\mathbf{W}\|_F^2, \qquad a_i = \frac{\beta_{s(i)}}{\sum_j \beta_{s(j)}}, \tag{4}$$

где $s(i)$ — испытуемый окна i, $\ell(y, \mathbf{z}) = -z_y + \log \sum_c e^{z_c}$, $\lambda > 0$. Предполагается, что у каждого испытуемого есть окна всех классов. Тогда все классы есть в любой бутстреп-выборке, и доли классов $\pi_c = \sum_{i:\, y_i = c} a_i$ положительны; обозначим $\boldsymbol{\pi} = (\pi_1, \ldots, \pi_L)$.

Решение задачи (4) при этом существует, его матрица весов единственна, а смещение единственно с точностью до общей константы, не меняющей вероятностей. Вектор $\mathbf{z}(\mathbf{X};\boldsymbol{\theta}) = \hat{\mathbf{W}}_{\boldsymbol{\theta}}\mathbf{x}_S + \hat{\mathbf{b}}_{\boldsymbol{\theta}}$ называется вектором логитов дерева, а выход дерева есть вектор вероятностей классов $f(\mathbf{X};\boldsymbol{\theta}) = \operatorname{softmax}\mathbf{z}(\mathbf{X};\boldsymbol{\theta}) \in \Delta_L$, где $\operatorname{softmax}(\mathbf{z})_c = e^{z_c}/\sum_{c'} e^{z_{c'}}$, а Δ_L — симплекс вероятностных векторов.

Лес. Параметры деревьев $\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_K$ независимы, одинаково распределены и не зависят от данных. Лес усредняет вероятности классов и относит окно к классу с наибольшим средним:

$$F_K(\mathbf{X}) = \frac{1}{K}\sum_{k=1}^{K} f(\mathbf{X};\boldsymbol{\theta}_k), \qquad \hat{y}_K(\mathbf{X}) = \arg\max_c F_{K,c}(\mathbf{X}). \tag{5}$$

Лес с усреднением логитов имеет выход $\operatorname{softmax}\big(K^{-1}\sum_k \mathbf{z}(\mathbf{X};\boldsymbol{\theta}_k)\big)$; по теореме 3 при сильной регуляризации он в первом приближении совпадает с (5). При фиксированных данных $\bar{f}(\mathbf{X}) = \mathbb{E}_{\boldsymbol{\theta}} f(\mathbf{X};\boldsymbol{\theta})$ есть выход бесконечного леса, а $\hat{y}_\infty(\mathbf{X}) = \arg\max_c \bar{f}_c(\mathbf{X})$ — его ответ; при равенстве компонент выбирается класс с наименьшим номером. Для распределения P пар $(\mathbf{X}, y)$ из окна и его метки доля ошибок выхода F равна $\mathcal{E}_P^{01}(F) = \mathbb{P}_P\big(\arg\max_c F_c(\mathbf{X}) \neq y\big)$. Сбалансированная точность выхода на наборе окон есть средняя по классам доля окон класса, отнесенных к нему; постоянный ответ дает $1/L$.

Область применимости результатов. Теорема 1 использует лишь то, что деревья суть независимые одинаково распределенные функции своих параметров и данных, и верна для любой конструкции дерева, в частности для реализации раздела 5. Теорема 2 есть утверждение о случайных подмножествах каналов. Предложение 1 и теорема 3 относятся к деревьям (3), (4) с общей опорной точкой сессии $\mathbf{M}$.

4 Основные результаты

Доказательства утверждений этого раздела собраны в приложении А.

4.1 Геометрия дерева

Для $\mathbf{Q} \in \mathbb{R}^{m\times h}$ с $\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_m$ матрица $\mathbf{Q}\mathbf{C}\mathbf{Q}^\top$ называется сжатием $\mathbf{C}$ на пространство строк $\mathbf{Q}$; ее квадратичная форма есть ограничение квадратичной формы $\mathbf{C}$ на m-мерное подпространство. Обозначим через $\mathbf{P}_S \in \{0,1\}^{d_m\times d}$ матрицу, оставляющую в векторе $\operatorname{vec}_{\sqrt{2}}\mathbf{S}$ координаты пар каналов (k,l), $k \leqslant l$, с $k,l \in S$, так что $\operatorname{vec}_{\sqrt{2}}\mathbf{S}_S = \mathbf{P}_S \operatorname{vec}_{\sqrt{2}}\mathbf{S}$ для любой $\mathbf{S} \in \operatorname{Sym}(h)$. Эта матрица связывает признаки дерева с признаками всех каналов в пункте (г) следующего предложения и в теореме 3.

Предложение 1 (о геометрии дерева)**.** *Пусть* $\mathbf{M} \in \mathbb{S}_+^h$, $|S| = m$, $\mathbf{C} = \mathbf{M}^{-1/2}\mathbf{R}\mathbf{M}^{-1/2}$ *и* $\mathbf{S} = \log\mathbf{C}$.

(а) *Матрица* $\mathbf{Q}_S = \mathbf{M}_S^{-1/2}\mathbf{E}_S^\top\mathbf{M}^{1/2} \in \mathbb{R}^{m\times h}$ *удовлетворяет* $\mathbf{Q}_S\mathbf{Q}_S^\top = \mathbf{I}_m$, *и отбеленная подматрица есть сжатие отбеленной ковариации:*

$$\mathbf{M}_S^{-1/2}\mathbf{R}_S\mathbf{M}_S^{-1/2} = \mathbf{Q}_S\mathbf{C}\mathbf{Q}_S^\top. \tag{6}$$

Если $\mathbf{M}$ *диагональна, то* $\mathbf{Q}_S = \mathbf{E}_S^\top$ *и отбеленная подматрица равна подматрице* $\mathbf{C}_S$ *отбеленной ковариации.*

(б) *Для любых* $\mathbf{R}, \mathbf{R}' \in \mathbb{S}_+^h$ *выполнено* $\delta_{\mathcal{R}}(\mathbf{R}_S, \mathbf{R}'_S) \leqslant \delta_{\mathcal{R}}(\mathbf{R}, \mathbf{R}')$. *В частности,* $\|\mathbf{x}_S\|_2 \leqslant \|\mathbf{x}\|_2$.

(в) $\omega(\mathbf{\Lambda}_S) \leqslant \omega(\mathbf{S})$.

(г) *Пусть* $\tau = \|\mathbf{S}\|_F$. *Тогда* $\left\|\mathbf{x}_S - \mathrm{vec}_{\sqrt{2}}(\mathbf{Q}_S\mathbf{S}\mathbf{Q}_S^\top)\right\|_2 \leqslant 2\tau$, *а при* $\tau < \log 2$

$$\left\|\mathbf{x}_S - \mathrm{vec}_{\sqrt{2}}\left(\mathbf{Q}_S\mathbf{S}\mathbf{Q}_S^\top\right)\right\|_2 \leqslant \varphi(\tau) = -\log\left(2 - e^\tau\right) - \tau = \tau^2 + O(\tau^3). \tag{7}$$

Если $\mathbf{M}$ *диагональна, то* $\mathrm{vec}_{\sqrt{2}}(\mathbf{Q}_S\mathbf{S}\mathbf{Q}_S^\top) = \mathbf{P}_S\mathbf{x}$.

По пунктам (б) и (в) отбеленные подматрицы дерева удовлетворяют условиям оценки искажения расстояний из теоремы 2 работы [10] с наибольшим спектральным разбросом ω и геодезическим радиусом $\rho = \max_i \delta_{\mathcal{R}}(\mathbf{M}, \mathbf{R}_i)$, не большими, чем у отбеленных ковариаций всех каналов. Доказательство этой оценки использует лишь то, что признаки суть логарифмы отбеленных матриц, а не то, что опорная точка есть риманово среднее. Поэтому для каждого дерева отношение геодезического расстояния между двумя окнами к евклидову расстоянию между их признаками лежит между 1 и $\min\{g(\omega), g(\sqrt{2}\rho)\}$, где $g(x) = \sinh(x/2)/(x/2)$. Главная подматрица выборочной ковариации есть выборочная ковариация m каналов, поэтому по теореме 3 и следствиям 1, 2 работы [10] шум ковариации, оцененной по $\mathcal{T}$ отсчетам, имеет в признаках дерева порядок $m/\sqrt{\mathcal{T}}$, а не $h/\sqrt{\mathcal{T}}$. По пункту (г) при диагональной опорной точке признаки дерева совпадают с частью признаков всех каналов с точностью до члена порядка τ^2, где τ — геодезическое расстояние от окна до опорной точки.

Замечание. Пункт (б) верен для отображения $\mathbf{R} \mapsto \mathbf{Q}\mathbf{R}\mathbf{Q}^\top$ с любой матрицей $\mathbf{Q}$ полного строчного ранга. Для лог-евклидова расстояния $\|\log\mathbf{R} - \log\mathbf{R}'\|_F$ [52] аналогичное утверждение неверно: для $\mathbf{R} = \exp\mathrm{diag}(-10, 10)$ и $\mathbf{R}' = \exp\left(\mathrm{diag}(-10, 10) + 0{,}01(\mathbf{e}_1\mathbf{e}_2^\top + \mathbf{e}_2\mathbf{e}_1^\top)\right)$ переход к элементам $(1,1)$ увеличивает лог-евклидово расстояние с 0,014 до 4,81, тогда как геодезическое расстояние уменьшается с 6,81 до 4,81. Поэтому опорные точки деревьев предпочтительно задавать в аффинно-инвариантной геометрии. Оценка (7) консервативна: член второго порядка разности равен $\frac{1}{2}\mathbf{Q}_S\mathbf{S}(\mathbf{I} - \mathbf{Q}_S^\top\mathbf{Q}_S)\mathbf{S}\mathbf{Q}_S^\top$, и его норма не превосходит $\tau^2/4$.

Замечание. По теореме 1 работы [10] при смешивании каналов $\mathbf{R} \mapsto \mathbf{A}\mathbf{R}\mathbf{A}^\top$ признаки всех каналов поворачиваются одной ортогональной матрицей, если опорная точка преобразуется так же: $\mathbf{M} \mapsto \mathbf{A}\mathbf{M}\mathbf{A}^\top$. Дерево сохраняет это свойство, если блок $\mathbf{A}_{S,S^c}$ со строками из S и столбцами из дополнения S^c нулевой: тогда $(\mathbf{A}\mathbf{R}\mathbf{A}^\top)_S = \mathbf{A}_{SS}\mathbf{R}_S\mathbf{A}_{SS}^\top$,

и та же теорема применима к m каналам дерева. При $m \leqslant h-1$ это условие выполнено для всех подмножеств сразу тогда и только тогда, когда $\mathbf{A}$ диагональна, то есть смешивание умножает каждый канал на свой ненулевой множитель, его усиление. Поэтому если все окна перецентрированы одной такой опорной точкой, например римановым средним всех окон, лес инвариантен к усилениям каналов. Если же у каждой сессии своя опорная точка, поворот зависит от сессии, и классификатор, обученный на нескольких сессиях, инвариантным быть не обязан; лог-евклидово среднее этим правилом не преобразуется даже при диагональной $\mathbf{A}$.

4.2 Число деревьев

Следующая теорема отделяет ошибку, вносимую конечностью леса, от ошибки бесконечного леса. Она верна при фиксированных обучающих данных для любого распределения тестовых окон, в том числе для окон нового испытуемого.

Теорема 1 (о конечном лесе)**.** *Пусть обучающие данные фиксированы, $\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K$ независимы и одинаково распределены, а P — произвольное распределение пар $(\mathbf{X}, y)$. Обозначим через $V(\mathbf{X}) = \mathbb{E}_{\boldsymbol{\theta}} \|f(\mathbf{X}; \boldsymbol{\theta}) - \bar{f}(\mathbf{X})\|_2^2$ дисперсию деревьев в точке $\mathbf{X}$, а через $\mathcal{E}_P(F) = \mathbb{E}_{(\mathbf{X},y)\sim P}\, \mathcal{L}(F(\mathbf{X}), y)$ риск выхода F для функции потерь $\mathcal{L}$ на векторах вероятностей.*

(а) Для квадратичной функции потерь $\mathcal{L}(\mathbf{q}, y) = \|\mathbf{q} - \mathbf{e}_y\|_2^2$ избыточный риск леса равен

$$\mathbb{E}_{\boldsymbol{\theta}}\, \mathcal{E}_P(F_K) - \mathcal{E}_P(\bar{f}) = \frac{1}{K}\, \mathbb{E}_P V(\mathbf{X}). \tag{8}$$

(б) Если $\mathcal{L}(\cdot, y)$ выпукла на Δ_L при каждом y, принимает значения в $\mathbb{R} \cup \{+\infty\}$ и ограничена снизу, то $\mathbb{E}_{\boldsymbol{\theta}} \mathcal{E}_P(F_K)$ не возрастает по K и не меньше $\mathcal{E}_P(\bar{f})$. Если $\mathcal{L}(\cdot, y)$ к тому же непрерывна и ограничена на Δ_L, то $\mathbb{E}_{\boldsymbol{\theta}} \mathcal{E}_P(F_K) \to \mathcal{E}_P(\bar{f})$.

(в) Пусть запас $\gamma(\mathbf{X})$ бесконечного леса на окне $\mathbf{X}$ есть разность двух наибольших компонент $\bar{f}(\mathbf{X})$. Тогда

$$\mathbb{P}_{\boldsymbol{\theta}}\big(\hat{y}_K(\mathbf{X}) \neq \hat{y}_\infty(\mathbf{X})\big) \leqslant (L-1)\, e^{-K\gamma(\mathbf{X})^2/2}, \tag{9}$$

и $\big|\mathbb{E}_{\boldsymbol{\theta}} \mathcal{E}_P^{01}(F_K) - \mathcal{E}_P^{01}(\bar{f})\big| \leqslant (L-1)\, \mathbb{E}_P\, e^{-K\gamma(\mathbf{X})^2/2}$.

(г) Пусть $K = Br$, и стратифицированный лес F_K^{str} содержит ровно r деревьев каждой полосы с независимыми S и $\boldsymbol{\beta}$. Обозначим $\bar{f}_b(\mathbf{X}) = \mathbb{E}[f(\mathbf{X}; \boldsymbol{\theta}) \mid b]$ и $V_B(\mathbf{X}) = B^{-1} \sum_b \|\bar{f}_b(\mathbf{X}) - \bar{f}(\mathbf{X})\|_2^2$. Тогда для квадратичной функции потерь

$$\mathbb{E}\, \mathcal{E}_P(F_K^{\mathrm{str}}) - \mathcal{E}_P(\bar{f}) = \frac{1}{K}\, \mathbb{E}_P\big[V(\mathbf{X}) - V_B(\mathbf{X})\big]. \tag{10}$$

Замечание. Тождество (8) есть стандартное разложение среднеквадратичной ошибки среднего независимых одинаково распределенных предсказателей, записанное для

векторов вероятностей. Оценка (9) объясняет, почему ошибка с ростом K быстро перестает уменьшаться: ответ конечного леса на окне с запасом γ отличается от ответа бесконечного с вероятностью не больше p_0 уже при $K \geqslant 2\log\big((L-1)/p_0\big)/\gamma^2$. По (10) равное число деревьев на полосу уменьшает избыточный риск на $K^{-1}\mathbb{E}_P V_B \geqslant 0$, не меняя бесконечного леса.

4.3 Разнообразие деревьев и структурированная регуляризация

Усреднение уменьшает дисперсию леса лишь постольку, поскольку деревья не вполне коррелированы. Два дерева видят часть касательных координат вместе, и в модели пункта (в) теоремы 3 они коррелированы только через эти координаты. Следующая теорема дает их ожидаемую долю, называемую далее долей общих координат.

Теорема 2 (об общих координатах и покрытии)**.** *Пусть $h \geqslant 2$, S, S' — независимые равновероятные подмножества $\{1,\dots,h\}$ из m элементов, $k_\cap = |S \cap S'|$, а $N_\cap = k_\cap(k_\cap+1)/2$ — число касательных координат пар каналов (k,l), $k \leqslant l$, из $S \cap S'$. Тогда*

$$\eta_h(m) := \frac{\mathbb{E}N_\cap}{d_m} = \frac{m\big[(m-1)^2 + 2(h-1)\big]}{h(h-1)(m+1)}. \tag{11}$$

Функция η_h строго возрастает по m, $\eta_h(1) = 1/h$, $\eta_h(h) = 1$, и $\eta_h(m) \to \alpha^2$ при $h \to \infty$, $m/h \to \alpha \in (0,1]$. Вероятность включения диагональной координаты в дерево равна $\varpi_{\text{diag}} = m/h$, а внедиагональной, описывающей связь между двумя каналами, — $\varpi_{\text{off}} = m(m-1)/(h(h-1))$. При $m \geqslant 2$ в лесу из K деревьев число деревьев, содержащих данную связь, имеет биномиальное распределение с параметрами K и ϖ_{off}, а ожидаемое число связей, не попавших ни в одно дерево, равно $\binom{h}{2}(1-\varpi_{\text{off}})^K$.

Связать долю общих координат с выходом леса позволяют два упрощения. Во-первых, признаки дерева должны быть координатами признаков всех каналов; по пункту (г) предложения 1 это верно при диагональной опорной точке с точностью до второго порядка по τ. Во-вторых, вес, который дерево придает координате, не должен зависеть от того, какие еще координаты видит дерево; это верно в пределе сильной регуляризации, который при фиксированной полосе описывает следующая теорема. Для весов a_i с $\sum_i a_i = 1$ обозначим через $\bar{\mathbf{x}}_a = \sum_i a_i \mathbf{x}_i$ взвешенное среднее признаков, через $\boldsymbol{\mu}_c = \pi_c^{-1} \sum_{i:\, y_i = c} a_i \mathbf{x}_i$ взвешенное среднее класса c, а через

$$\mathbf{G} = \sum_{i=1}^{N} a_i \left(\mathbf{e}_{y_i} - \boldsymbol{\pi}\right) \mathbf{x}_i^\top \in \mathbb{R}^{L \times d} \tag{12}$$

матрицу, строка c которой равна $\pi_c(\boldsymbol{\mu}_c - \bar{\mathbf{x}}_a)^\top$. Пусть $\mathbf{1}$ — вектор из единиц, а $\mathbf{W}_{:,p}$ — столбец p матрицы $\mathbf{W}$.

Теорема 3 (о пределе сильной регуляризации)**.** *Пусть $m \geqslant 2$, признаки дерева суть координаты признаков всех каналов, $\mathbf{x}_S = \mathbf{P}_S\mathbf{x}$, веса a_i в (4) удовлетворяют $\sum_i a_i = 1$, и все классы представлены, $\pi_c > 0$.*

(а) При $\lambda \to \infty$ решение задачи (4) удовлетворяет $2\lambda \hat{\mathbf{W}}_{\boldsymbol{\theta}} \to \mathbf{G}\mathbf{P}_S^\top$, а логиты дерева равны

$$\mathbf{z}(\mathbf{X};\boldsymbol{\theta}) = \log \boldsymbol{\pi} + c_\lambda \mathbf{1} + \frac{1}{2\lambda}\,\mathbf{G}\mathbf{P}_S^\top \mathbf{P}_S\big(\mathbf{x} - \bar{\mathbf{x}}_a\big) + o(\lambda^{-1}) \tag{13}$$

равномерно по $\mathbf{x}$ из ограниченных множеств, где c_λ — скаляр. Вес, который дерево придает координате, не зависит от остальных координат дерева.

(б) Пусть полоса фиксирована, а $\boldsymbol{\pi}$ и $\bar{\mathbf{x}}_a$ одинаковы для всех бутстреп-выборок. Обозначим через $\mathbf{G}_{\boldsymbol{\beta}}$ матрицу (12) для весов бутстреп-выборки $\boldsymbol{\beta}$, $\bar{\mathbf{G}} = \mathbb{E}_{\boldsymbol{\beta}}\mathbf{G}_{\boldsymbol{\beta}}$, а через $\boldsymbol{\Pi} = \mathbb{E}_S \mathbf{P}_S^\top \mathbf{P}_S$ диагональную матрицу вероятностей включения координат ϖ_{diag} и ϖ_{off}. Тогда бесконечный лес и бесконечный лес с усреднением логитов имеют выход

$$\operatorname{softmax}\Big(\log \boldsymbol{\pi} + \frac{1}{2\lambda}\,\bar{\mathbf{G}}\boldsymbol{\Pi}\big(\mathbf{x} - \bar{\mathbf{x}}_a\big)\Big) + o(\lambda^{-1}). \tag{14}$$

Пусть, кроме того, $\bar{\mathbf{G}}$, $\boldsymbol{\pi}$ и $\bar{\mathbf{x}}_a$ совпадают с матрицей (12), долями классов и средним, вычисленными с весами $a_i = 1/N$. Логистическую регрессию на всех каналах с весами $1/N$ и штрафом $\lambda \sum_p \|\mathbf{W}_{:,p}\|_2^2/\varpi_p$, где ϖ_p — вероятность включения координаты p, назовем структурированной регрессией. Ее выход также равен (14).

(в) Пусть $L = 2$, $\mathbf{g} \in \mathbb{R}^d$ — разность строк $\mathbf{G}$, и все координаты $\mathbf{g}$ равны по модулю. Пусть признаки тестового окна имеют вид $\mathbf{x} = \boldsymbol{\mu} + \boldsymbol{\varepsilon}$, где $\boldsymbol{\mu}$ — средние признаки его класса, а шум $\boldsymbol{\varepsilon}$ имеет $\operatorname{Cov}\boldsymbol{\varepsilon} = \sigma^2 \mathbf{I}_d$; такую модель назовем изотропной. Рассмотрим деревья с общими полосой и бутстреп-выборкой и независимыми подмножествами; главный член разности логитов дерева с подмножеством S равен $u_S = \langle \mathbf{P}_S\mathbf{g}, \mathbf{P}_S\mathbf{x}\rangle$. Тогда

$$\begin{aligned} \frac{\mathbb{E}_{S,S'} \operatorname{Cov}_{\boldsymbol{\varepsilon}}(u_S, u_{S'})}{\mathbb{E}_S \operatorname{Var}_{\boldsymbol{\varepsilon}}(u_S)} &= \eta_h(m), \\ \frac{\mathbb{E}_{S_1,\ldots,S_K} \operatorname{Var}_{\boldsymbol{\varepsilon}}\left(\frac{1}{K}\sum_k u_{S_k}\right)}{\mathbb{E}_S \operatorname{Var}_{\boldsymbol{\varepsilon}}(u_S)} &= \eta_h(m) + \frac{1-\eta_h(m)}{K}. \end{aligned} \tag{15}$$

Левая часть первого равенства называется корреляцией двух деревьев.

Замечание. По пункту (а) сильно регуляризованное дерево есть взвешенная разность средних классов: с точностью до общей константы его логит класса c равен $\log \pi_c + (2\lambda)^{-1}\pi_c\langle \mathbf{P}_S(\boldsymbol{\mu}_c - \bar{\mathbf{x}}_a), \mathbf{P}_S(\mathbf{x} - \bar{\mathbf{x}}_a)\rangle$. По пункту (б) лес есть одна линейная модель на признаках всех каналов, в которой веса связей между каналами ослаблены относительно весов мощностей каналов в $\varpi_{\text{diag}}/\varpi_{\text{off}} = (h-1)/(m-1)$ раз. Таким образом, случайные подмножества каналов действуют как структурированная регуляризация, тем более сильная, чем меньше m, а бэггинг испытуемых заменяет матрицу средних классов ее средним по бутстреп-выборкам. Для B полос усреднение по полосам дает структурированную регрессию на объединенных признаках всех полос со штрафом $\lambda B \sum_p \|\mathbf{W}_{:,p}\|_2^2/\varpi_p$.

Замечание. Условия пункта (б) на $\boldsymbol{\pi}$ и $\bar{\mathbf{G}}$ выполнены, если у всех испытуемых одинаковое число окон и классы сбалансированы внутри каждого испытуемого, а условие на $\bar{\mathbf{x}}_a$ — если средние признаки всех испытуемых совпадают. Перецентрирование каждой сессии ее римановым средним обнуляет средние признаки всех каналов в силу характеризующего его равенства; такая опорная точка не диагональна, поэтому предположение $\mathbf{x}_S = \mathbf{P}_S\mathbf{x}$ и условие на $\bar{\mathbf{x}}_a$ выполняются одновременно лишь приближенно.

Замечание. Пункт (в) есть аналог известной формулы для дисперсии среднего коррелированных деревьев [31]. Он относится к части дисперсии, вызванной выбором подмножеств каналов, при фиксированных полосе и бутстреп-выборке. Дисперсия леса не может опуститься ниже произведения $\eta_h(m)$ на дисперсию дерева, а убывающий по K член $(1-\eta_h)/K$ становится меньше десятой доли этого уровня при $K \geqslant 10(1-\eta_h)/\eta_h$. Малое m понижает этот уровень, но каждое дерево видит лишь долю d_m/d координат, и за это приходится платить покрытием: по теореме 2 данная связь не попадает ни в одно дерево с вероятностью $(1-\varpi_{\text{off}})^K$. Если координаты $\mathbf{g}$ различаются по модулю, корреляция отличается от $\eta_h(m)$: например, при $|g_p| = 2$ для диагональных координат, $|g_p| = 0{,}5$ для внедиагональных, $h = 6$ и $m = 3$ она равна 0,48 против $\eta_6(3) = 0{,}35$.

4.4 Внебутстреповая оценка по испытуемым

Обычно ошибку на новом испытуемом оценивают поочередным исключением испытуемых, и модель переобучается n раз. Внебутстреповая, или out-of-bag, оценка [39] обходится без переобучения: ошибка на испытуемом вычисляется только по деревьям, в бутстреп-выборку которых он не попал. Новым называется испытуемый, данные которого не зависят от данных испытуемых обучающей выборки и имеют то же распределение. Для испытуемого s обозначим через $\beta_{k,s}$ его кратность в бутстреп-выборке дерева k, через $\mathcal{K}_s = \{k\colon \beta_{k,s} = 0\}$ множество деревьев, в которые он не попал, и через $F^{(-s)} = |\mathcal{K}_s|^{-1}\sum_{k\in\mathcal{K}_s} f(\cdot\,;\boldsymbol{\theta}_k)$ их среднее. Для меры ошибки $\mathcal{Q}(F, \mathcal{Z})$ выхода F на окнах $\mathcal{Z}$ испытуемого, например средней потери или единицы минус сбалансированная точность, внебутстреповая оценка по испытуемым есть среднее $\mathcal{Q}(F^{(-s)}, \mathcal{Z}_s)$ по испытуемым с $\mathcal{K}_s \neq \varnothing$.

Предложение 2 (о внебутстреповой оценке по испытуемым)**.** *Пусть данные испытуемых $\mathcal{Z}_1, \ldots, \mathcal{Z}_n$ независимы и одинаково распределены, дерево с параметром $\boldsymbol{\theta}$ зависит от данных только через испытуемых с $\beta_s > 0$ и их кратности, а $\mathcal{Q}$ измерима.*

(а) $|\mathcal{K}_s|$ имеет биномиальное распределение с параметрами K и $q_n = (1-1/n)^n$, причем $1/4 \leqslant q_n < e^{-1}$ при $n \geqslant 2$; в частности, $\mathbb{P}(\mathcal{K}_s = \varnothing) \leqslant (3/4)^K$.

(б) При условии $|\mathcal{K}_s| = k \geqslant 1$ выход $F^{(-s)}$ распределен как лес из k деревьев, обученный на $n-1$ независимых испытуемых с бутстреп-выборками объема n, и не зависит от $\mathcal{Z}_s$, так что

$$\mathbb{E}\big[\mathcal{Q}(F^{(-s)}, \mathcal{Z}_s) \,\big|\, |\mathcal{K}_s| = k\big] = \mathcal{E}_{n-1}(k), \tag{16}$$

где $\mathcal{E}_{n-1}(k)$ — ожидаемая ошибка такого леса на новом испытуемом.

(в) Если $\mathcal{Q}$ есть среднее по окнам функции потерь, выпуклой по вероятностям и ограниченной снизу, то $\mathcal{E}_{n-1}(k)$ не возрастает по k и не меньше ожидаемой потери бесконечного леса, обученного на $n-1$ испытуемых с бутстреп-выборками объема n. Внебутстреповая оценка тогда консервативна для этого бесконечного леса, то есть в среднем не занижает его ошибку.

Замечание. Предложение требует, чтобы все шаги построения дерева, в том числе априорная опорная точка и стандартизация признаков, вычислялись по испытуемым его бутстреп-выборки. Перецентрирование окон оцениваемого испытуемого его собственной опорной точкой этому не противоречит: оно использует только неразмеченные окна этого испытуемого, как и на новом испытуемом. При $n = 10$ доля деревьев, в которые данный испытуемый не попал, в среднем равна $q_{10} \approx 0{,}35$, так что лес из $K = 50$ деревьев дает около 17 таких деревьев на испытуемого. Поэтому внебутстреповые оценки при разных m относятся к лесам примерно из $q_n K$ деревьев. Для доли ошибок и сбалансированной точности, не выпуклых по вероятностям, утверждение пункта (в) может не выполняться.

4.5 Следствия для построения леса

Опорная точка. Риманово среднее сессии, главными подматрицами которого все деревья перецентрируют свои ковариации, делает все деревья сжатиями одной отбеленной ковариации. Если все окна перецентрированы одной такой опорной точкой, лес также инвариантен к усилениям каналов.

Полосы. Стратифицированный выбор полос уменьшает избыточный риск конечного леса, не меняя бесконечного.

Размер подмножества и число деревьев. По теореме 3 малое m снижает корреляцию деревьев и усиливает штраф на связи между каналами, а по теореме 2 требует больше деревьев для покрытия этих связей. Касательные координаты разных полос различны, поэтому оба требования относятся к числу деревьев на полосу K/B, и раздельное рассмотрение полос дает правило

$$\frac{K}{B} \geqslant \max\left\{\frac{\log(1/\epsilon)}{-\log(1-\varpi_{\text{off}})},\ \frac{10\,(1-\eta_h(m))}{\eta_h(m)}\right\}, \tag{17}$$

где ϵ — допустимая вероятность пропуска связи в полосе. При $h = 41$ и $\epsilon = 0{,}01$ первый член равен 18 при $m = 20$ и 55 при $m = 12$. Поскольку $\eta_{41}(20) = 0{,}256$ и $\eta_{41}(12) = 0{,}113$, второй член равен 30 и 79 соответственно. Связи при этом ослабляются в $(h-1)/(m-1) = 2{,}1$ и $3{,}6$ раза.

Базовый метод и подбор параметров. Лес следует сравнивать со структурированной регрессией теоремы 3: разность их ошибок показывает, что дают сверх структурированной регуляризации перецентрирование подматриц и усреднение вероятностей. Внебутстреповая оценка предложения 2 позволяет выбирать m и K без кроссвалидации.

5 Вычислительный эксперимент

Эксперимент отвечает на два вопроса. Синтетическая часть проверяет, насколько идеализированные предсказания теорем 2 и 3 описывают обученные деревья: корреляцию деревьев, дисперсию леса как функцию K, согласие леса со структурированной регрессией и выигрыш от этой регуляризации, когда связи между каналами несут мало сигнала. Часть на данных ЭЭГ проверяет, превосходит ли лес один касательный классификатор при переносе между испытуемыми.

Синтетические данные. Число каналов $h = 16$, так что $d = 136$; опорная точка — единичная матрица, она диагональна. Окно класса $y \in \{0, 1\}$ имеет ковариацию $\mathbf{R} = \exp \mathbf{S}$ с $\mathrm{vec}_{\sqrt{2}} \mathbf{S} = (2y - 1)\sigma \mathbf{u} + \sigma \boldsymbol{\xi}$, где $\mathbf{u}$ — единичное направление, выбираемое один раз для задачи, $\boldsymbol{\xi}$ — стандартный нормальный вектор, а σ — уровень шума. Шум, таким образом, изотропен в касательных координатах, как в пункте (в) теоремы 3. Байесовский классификатор относит окно к классу $y = 1$ при $\langle \mathbf{u}, \mathrm{vec}_{\sqrt{2}} \mathbf{S} \rangle > 0$; эта проекция имеет среднее $\pm\sigma$ и стандартное отклонение σ, поэтому наибольшая достижимая точность равна 0,84, значению функции стандартного нормального распределения в точке 1. Уровням шума $\sigma = 0{,}02$ и $\sigma = 0{,}15$ отвечает расстояние до опорной точки $\tau = \|\mathbf{S}\|_F$ около 0,23 и 1,8 соответственно. Дерево видит точные признаки $\mathrm{vec}_{\sqrt{2}} \log \mathbf{R}_S$, а не их линеаризацию, и обучает бинарную логистическую регрессию библиотеки scikit-learn с параметром C_{sk}. Вектор весов этой модели есть разность двух строк $\mathbf{W}$ в (4), квадрат его нормы вдвое меньше квадрата нормы $\mathbf{W}$, поэтому $C_{\mathrm{sk}} = 1/(\lambda N)$. Решающее значение дерева есть разность двух его логитов. Обучающая выборка содержит 400 окон, тестовая — 2000.

Корреляция и дисперсия деревьев. Корреляция двух деревьев измеряется как в пункте (в) теоремы 3 при сильной регуляризации, $C_{\mathrm{sk}} = 10^{-3}$. Решающие значения каждого дерева на тестовых окнах центрируются внутри каждого класса; их ковариация для пары деревьев, усредненная по парам, делится на среднюю дисперсию. На рис. 1 а корреляция показана при m от 2 до 16 для трех постановок: направления $\mathbf{u}$ с равными по модулю координатами, как в теореме, и гауссова направления при $\sigma = 0{,}02$ и $\sigma = 0{,}15$; каждое значение усреднено по пяти задачам. Во всех трех постановках корреляция совпадает с $\eta_h(m)$ в пределах стандартного отклонения по задачам, так что в этих постановках условие равенства координат по модулю можно снять. На рис. 1 б показана дисперсия среднего K деревьев относительно дисперсии

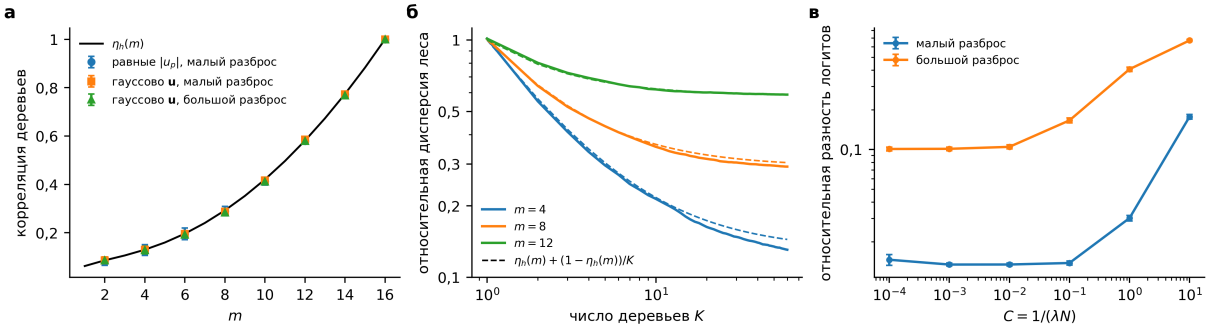


Рис. 1. Синтетические данные, $h = 16$. **а** Корреляция деревьев и доля общих координат $\eta_h(m)$; средние и стандартные отклонения по пяти задачам. **б** Дисперсия среднего K деревьев относительно одного дерева, сплошные линии, и предсказание $\eta_h(m) + (1 - \eta_h(m))/K$ теоремы 3, пунктир. **в** Относительная разность решающих значений леса с усреднением логитов и структурированной регрессии, $m = 8$, в зависимости от параметра регуляризации

одного дерева при $\sigma = 0{,}15$: она следует предсказанию $\eta_h(m) + (1 - \eta_h(m))/K$ и приближается к уровню $\eta_h(m)$, равному 0,13, 0,29 и 0,58 при $m = 4$, 8 и 12.

Лес и структурированная регрессия. При $m = 8$ лес из 200 деревьев с усреднением логитов сравнивается со структурированной регрессией, в которой вероятности включения заменены частотами включения в выбранные подмножества. На рис. 1в показана норма разности их решающих значений на тестовых окнах относительно стандартного отклонения решающих значений регрессии, усредненная по трем задачам. При сильной регуляризации относительная разность составляет 1,3 % при $\sigma = 0{,}02$ и достигает 10 % при $\sigma = 0{,}15$. Отношение этих величин близко к отношению уровней шума 7,5: по пункту (г) предложения 1 относительная ошибка линеаризации имеет порядок τ. Теорема 3 описывает лишь первый порядок по $1/\lambda$, и с уменьшением λ разность растет.

Сигнал в мощностях каналов. По теореме 3 лес штрафует связи между каналами сильнее, чем мощности, и это должно помогать, когда связи несут меньше сигнала, чем мощности. В этой постановке направление **u** имеет ненулевые координаты только на диагонали, $\sigma = 0{,}1$, обучающая выборка содержит 60 окон, а лес — $K = 50$ деревьев. Для каждого метода приведена наилучшая точность на тестовой выборке по пяти значениям C_{sk} от 10^{-2} до 10^{2}, усредненная по десяти задачам; такой выбор завышает точность всех методов. Результаты сведены в табл. 1. Лес и структурированная регрессия с тем же m имеют близкую точность, и при $m = 4$ оба метода превосходят логистическую регрессию на всех каналах на 8 и 9 процентных пунктов соответственно; выигрыш уменьшается с ростом m вместе с множителем ослабления связей $(h - 1)/(m - 1)$.

Таблица 1. Синтетические данные, сигнал только в мощностях каналов: наилучшая по пяти значениям C_{sk} точность на тестовой выборке, среднее и стандартное отклонение по десяти задачам. Точность логистической регрессии на всех каналах равна $0{,}702 \pm 0{,}027$

Метод	$m = 4$	$m = 8$	$m = 12$
структурированная регрессия	$0{,}794 \pm 0{,}021$	$0{,}761 \pm 0{,}024$	$0{,}730 \pm 0{,}028$
лес	$0{,}777 \pm 0{,}037$	$0{,}761 \pm 0{,}021$	$0{,}728 \pm 0{,}024$

Данные ЭЭГ. Использован открытый набор PROTEUS [53]; на нем обучаются модели в задаче декодирования мысленных команд соревнования Neural Interface Foundation Challenge на конференции NeurIPS 2026 [54]. Набор содержит записи 10 испытуемых, 14 сессий, $h = 41$ канал ЭЭГ и три мысленные команды: кинестетическое воображение движения, счет в уме и генерацию слов. Предобработка повторяет официальную процедуру соревнования: режекторные фильтры 50 и 60 Гц, полоса 0,1–75 Гц, частота дискретизации 120 Гц, окно длиной 4 с, начинающееся через 1 с после подсказки. Шесть испытуемых используются для обучения, два — для валидации и два — для теста, что дает 1521, 379 и 755 окон соответственно.

Протокол. Качество измеряется сбалансированной точностью, вычисленной для каждой сессии и усредненной по сессиям; случайный уровень равен 1/3. Оценка выполняется в потоковом режиме соревнования: окна каждой сессии поступают по одному в порядке записи, каждая сессия начинается с исходного состояния модели, а признаки используют только потоковую опорную точку (2). На одних и тех же предсказаниях используемая реализация оценки дает те же значения, что и официальный код. По восьми обучающим и валидационным испытуемым вычислены две кросс-валидационные оценки: оценка с исключением одного испытуемого характеризует сбалансированную точность на новых испытуемых, а обучение на ранних сессиях с тестом на последней — на поздних сессиях знакомых испытуемых. Несколько сессий есть лишь у одного испытуемого, поэтому вторая оценка опирается на одного испытуемого. На официальном тестовом разбиении качество измерено один раз, для выбранного по кросс-валидации леса с $m = 20$ и для одного касательного классификатора.

Методы. Один касательный классификатор есть классификатор (4) на всех каналах в полосе 4–40 Гц без бэггинга, то есть дерево с $S = \{1, \ldots, h\}$. Лес (5) состоит из $K = 50$ деревьев с подмножествами из $m \in \{12, 20\}$ каналов; банк содержит $B = 6$ полос: 4–40, 4–8, 8–13, 13–20, 20–30 и 30–40 Гц. Каждое дерево перецентрирует свои подматрицы относительно их собственного бегущего среднего (2) с $w_0 = 5$ и центрирует и нормирует каждый признак его средним и стандартным отклонением по всем обучающим окнам. Ковариации оцениваются методом OAS [55], сдвигающим выборочную

Таблица 2. Сбалансированная точность на наборе PROTEUS, усредненная по сессиям. Новые испытуемые: исключение одного из восьми обучающих и валидационных испытуемых, среднее и стандартное отклонение по испытуемым. Поздние сессии: последняя сессия испытуемого с несколькими сессиями. Тест: официальное тестовое разбиение из двух испытуемых. Прочерк означает, что значение не вычислялось

Метод	новые испытуемые	поздние сессии	тест
постоянный ответ	0,333	0,333	0,333
EEGNet [54]	—	—	0,326
CTNet [54]	—	—	0,350
REVE с дообучением [54]	—	—	0,360
один касательный классификатор	$0{,}469 \pm 0{,}114$	0,547	0,455
лес, $m = 12$	$0{,}511 \pm 0{,}133$	0,614	—
лес, $m = 20$	$0{,}531 \pm 0{,}150$	0,669	0,529

ковариацию к матрице, пропорциональной единичной. Все модели используют одинаковую регуляризацию: $C_{\mathrm{sk}} = 0{,}01$ в многоклассовой модели scikit-learn, что отвечает $\lambda = 1/(2C_{\mathrm{sk}} \sum_i \beta_{s(i)})$ в (4). Реализация отличается от предположений предложения 1 и теоремы 3 в четырех отношениях: собственными лог-евклидовыми опорными точками деревьев, стандартизацией, регуляризацией ковариаций и сбалансированными по классам весами в логистической регрессии. Вариант, рекомендованный в разделе 4.5, не запускался. Априорная опорная точка и стандартизация дерева вычисляются по всем испытуемым обучающей выборки, а не по его бутстреп-выборке, поэтому условие предложения 2 нарушено и внебутстреповая оценка не вычислялась. Для сравнения приведены результаты нейросетевых моделей на том же тестовом разбиении, опубликованные организаторами [54]. Код леса доступен в открытом репозитории[1].

Результаты на данных ЭЭГ. Результаты сведены в табл. 2. Перецентрированный касательный классификатор превосходит опубликованные нейросетевые модели, сбалансированная точность которых на этом разбиении близка к случайной. Лес с $m = 20$ в среднем точнее одного классификатора во всех трех режимах, а лес с $m = 12$ — в обоих режимах кросс-валидации. Разности средних, от 0,04 до 0,12, сопоставимы со стандартным отклонением по испытуемым; парные сравнения по испытуемым не проводились, а оценка поздних сессий опирается на одну сессию. Сравнение не отделяет эффект подмножеств каналов от эффекта банка полос и бэггинга. При $K = 50$ и $B = 6$ на полосу приходится в среднем около 8 деревьев, много меньше требуемого правилом (17) для обоих значений m. Полосы выбираются независимо для каждого дерева, поэтому связь пропускается в полосе с вероятностью $(1 - \varpi_{\mathrm{off}}/B)^K$, равной около 0,14 при $m = 20$ и 0,51 при $m = 12$.

[1] https://github.com/DorinDaniil/Brain-Decoding

6 Заключение

Каждое дерево леса видит сжатие отбеленной ковариации всех каналов. Переход к нему не увеличивает ни геодезических расстояний, ни спектрального разброса, поэтому явные оценки [10] для касательных признаков выполняются для дерева с m каналами вместо h. Избыточный квадратичный риск конечного леса равен средней дисперсии деревьев, деленной на K. При сильной регуляризации и сбалансированных данных лес в первом приближении по $1/\lambda$ совпадает с одной логистической регрессией, штрафующей связи между каналами в $(h-1)/(m-1)$ раз сильнее мощностей каналов, а в изотропной модели корреляция двух деревьев равна доле общих координат $\eta_h(m)$. Вместе с покрытием связей это дает правило (17) выбора m и K. Внебутстреповая ошибка по испытуемым без переобучения оценивает ошибку на новом испытуемом леса, обученного без него. На синтетических данных обученные деревья следуют этим предсказаниям, а на наборе PROTEUS лес в среднем точнее одного касательного классификатора, хотя разница сопоставима со стандартным отклонением по испытуемым. Правило (17) предстоит проверить на нескольких наборах данных.

A Доказательства

A.1 Доказательство предложения 1

(а) Поскольку $\mathbf{E}_S^\top \mathbf{M} \mathbf{E}_S = \mathbf{M}_S$,

$$\mathbf{Q}_S \mathbf{Q}_S^\top = \mathbf{M}_S^{-1/2} \mathbf{E}_S^\top \mathbf{M}^{1/2} \mathbf{M}^{1/2} \mathbf{E}_S \mathbf{M}_S^{-1/2} = \mathbf{M}_S^{-1/2} \mathbf{M}_S \mathbf{M}_S^{-1/2} = \mathbf{I}_m.$$

Подставляя $\mathbf{R} = \mathbf{M}^{1/2} \mathbf{C} \mathbf{M}^{1/2}$ в $\mathbf{R}_S = \mathbf{E}_S^\top \mathbf{R} \mathbf{E}_S$, получаем

$$\mathbf{M}_S^{-1/2} \mathbf{R}_S \mathbf{M}_S^{-1/2} = \big(\mathbf{M}_S^{-1/2} \mathbf{E}_S^\top \mathbf{M}^{1/2}\big) \mathbf{C} \big(\mathbf{M}^{1/2} \mathbf{E}_S \mathbf{M}_S^{-1/2}\big) = \mathbf{Q}_S \mathbf{C} \mathbf{Q}_S^\top.$$

Если $\mathbf{M}$ диагональна, то $\mathbf{E}_S^\top \mathbf{M}^{1/2} = \mathbf{M}_S^{1/2} \mathbf{E}_S^\top$, откуда $\mathbf{Q}_S = \mathbf{E}_S^\top$.

(б) Докажем более общее утверждение: для $\mathbf{Q} \in \mathbb{R}^{m \times h}$ ранга m отображение $\Phi(\mathbf{R}) = \mathbf{Q} \mathbf{R} \mathbf{Q}^\top$ переводит $\mathbb{S}_+^h$ в $\mathbb{S}_+^m$ и не увеличивает геодезических расстояний. Положительная определенность следует из $\mathbf{v}^\top \mathbf{Q} \mathbf{R} \mathbf{Q}^\top \mathbf{v} > 0$ при $\mathbf{Q}^\top \mathbf{v} \neq \mathbf{0}$, то есть при $\mathbf{v} \neq \mathbf{0}$. Отображение Φ линейно, поэтому его дифференциал в любой точке есть $\mathbf{V} \mapsto \mathbf{Q} \mathbf{V} \mathbf{Q}^\top$. Зафиксируем $\mathbf{R} \in \mathbb{S}_+^h$, положим $\mathbf{Y} = \Phi(\mathbf{R})$ и $\tilde{\mathbf{Q}} = \mathbf{Y}^{-1/2} \mathbf{Q} \mathbf{R}^{1/2}$; как в пункте (а), $\tilde{\mathbf{Q}} \tilde{\mathbf{Q}}^\top = \mathbf{I}_m$. Для $\mathbf{V} \in \mathrm{Sym}(h)$ и $\mathbf{Z} = \mathbf{R}^{-1/2} \mathbf{V} \mathbf{R}^{-1/2}$ длина образа $\mathbf{V}$ в метрике точки $\mathbf{Y}$ равна

$$\big\|\mathbf{Q} \mathbf{V} \mathbf{Q}^\top\big\|_{\mathbf{Y}} = \big\|\mathbf{Y}^{-1/2} \mathbf{Q} \mathbf{R}^{1/2} \mathbf{Z} \mathbf{R}^{1/2} \mathbf{Q}^\top \mathbf{Y}^{-1/2}\big\|_F = \big\|\tilde{\mathbf{Q}} \mathbf{Z} \tilde{\mathbf{Q}}^\top\big\|_F \leqslant \|\mathbf{Z}\|_F = \|\mathbf{V}\|_{\mathbf{R}}.$$

Неравенство верно потому, что $\mathbf{H} = \tilde{\mathbf{Q}}^\top \tilde{\mathbf{Q}}$ есть ортогональный проектор, $\|\tilde{\mathbf{Q}} \mathbf{Z} \tilde{\mathbf{Q}}^\top\|_F^2 = \mathrm{tr}(\mathbf{H}\mathbf{Z}\mathbf{H}\mathbf{Z}) = \|\mathbf{H}\mathbf{Z}\mathbf{H}\|_F^2$, а $\|\mathbf{Z}\|_F^2 - \|\mathbf{H}\mathbf{Z}\mathbf{H}\|_F^2 = \|(\mathbf{I}-\mathbf{H})\mathbf{Z}\|_F^2 + \|\mathbf{H}\mathbf{Z}(\mathbf{I}-\mathbf{H})\|_F^2 \geqslant 0$, как видно из разложения $\mathbf{Z} = (\mathbf{H}+\mathbf{I}-\mathbf{H})\mathbf{Z}(\mathbf{H}+\mathbf{I}-\mathbf{H})$ на четыре взаимно ортогональных

блока. Таким образом, Φ не увеличивает длин касательных векторов, а значит, и длин кривых: для любой гладкой кривой $\boldsymbol{\varrho}$ из $\mathbf{R}$ в $\mathbf{R}'$ длина кривой $\Phi\circ\boldsymbol{\varrho}$ не превосходит длины $\boldsymbol{\varrho}$. Поскольку $\Phi\circ\boldsymbol{\varrho}$ соединяет $\Phi(\mathbf{R})$ и $\Phi(\mathbf{R}')$, а геодезическое расстояние есть нижняя грань длин соединяющих кривых, $\delta_{\mathcal{R}}(\Phi(\mathbf{R}),\Phi(\mathbf{R}'))\leqslant\delta_{\mathcal{R}}(\mathbf{R},\mathbf{R}')$; при $\mathbf{Q}=\mathbf{E}_S^\top$ это первое утверждение. По теореме 2 работы [10], примененной с опорной точкой $\mathbf{M}_S$ к m каналам, $\|\mathbf{x}_S\|_2=\delta_{\mathcal{R}}(\mathbf{M}_S,\mathbf{R}_S)$, и так же $\|\mathbf{x}\|_2=\delta_{\mathcal{R}}(\mathbf{M},\mathbf{R})$, откуда следует второе утверждение.

(в) Собственные значения $\mu_1\geqslant\ldots\geqslant\mu_m$ сжатия $\mathbf{Q}_S\mathbf{C}\mathbf{Q}_S^\top$ с $\mathbf{Q}_S\mathbf{Q}_S^\top=\mathbf{I}_m$ перемежаются с собственными значениями $\nu_1\geqslant\ldots\geqslant\nu_h$ матрицы $\mathbf{C}$ по теореме Коши о перемежаемости: $\nu_j\geqslant\mu_j\geqslant\nu_{j+h-m}$. В частности, $\nu_h\leqslant\mu_m\leqslant\mu_1\leqslant\nu_1$, и так как логарифм возрастает, $\omega(\boldsymbol{\Lambda}_S)=\log\mu_1-\log\mu_m\leqslant\log\nu_1-\log\nu_h=\omega(\mathbf{S})$.

(г) Обозначим $\mathbf{Q}=\mathbf{Q}_S$. По пункту (а) $\mathbf{x}_S=\operatorname{vec}_{\sqrt{2}}\log(\mathbf{Q}e^{\mathbf{S}}\mathbf{Q}^\top)$, а по изометричности $\operatorname{vec}_{\sqrt{2}}$ левая часть (7) равна $\|\log(\mathbf{Q}e^{\mathbf{S}}\mathbf{Q}^\top)-\mathbf{Q}\mathbf{S}\mathbf{Q}^\top\|_F$. Так как $\mathbf{Q}\mathbf{Q}^\top=\mathbf{I}_m$, запишем $\mathbf{Q}e^{\mathbf{S}}\mathbf{Q}^\top=\mathbf{I}_m+\mathbf{D}$ с $\mathbf{D}=\mathbf{Q}\mathbf{S}\mathbf{Q}^\top+\mathbf{D}_1$ и $\mathbf{D}_1=\mathbf{Q}\big(e^{\mathbf{S}}-\mathbf{I}-\mathbf{S}\big)\mathbf{Q}^\top$. Для матрицы с ортонормированными строками $\|\mathbf{Q}\mathbf{Z}\mathbf{Q}^\top\|_F\leqslant\|\mathbf{Z}\|_F$ по доказательству пункта (б), а норма Фробениуса субмультипликативна, поэтому

$$\|\mathbf{D}_1\|_F\leqslant\Big\|\sum_{k\geqslant2}\frac{\mathbf{S}^k}{k!}\Big\|_F\leqslant e^\tau-1-\tau,\qquad\|\mathbf{D}\|_F\leqslant e^\tau-1<1.$$

Спектральная норма не превосходит нормы Фробениуса, поэтому ряд $\log(\mathbf{I}+\mathbf{D})=\sum_{k\geqslant1}(-1)^{k+1}\mathbf{D}^k/k$ сходится, и

$$\big\|\log(\mathbf{I}+\mathbf{D})-\mathbf{D}\big\|_F\leqslant\sum_{k\geqslant2}\frac{\|\mathbf{D}\|_F^k}{k}=-\log(1-\|\mathbf{D}\|_F)-\|\mathbf{D}\|_F\leqslant-\log(2-e^\tau)-(e^\tau-1),$$

где последнее неравенство следует из возрастания функции $u\mapsto-\log(1-u)-u$ на $[0,1)$. Складывая, получаем $\|\log(\mathbf{Q}e^{\mathbf{S}}\mathbf{Q}^\top)-\mathbf{Q}\mathbf{S}\mathbf{Q}^\top\|_F\leqslant-\log(2-e^\tau)-\tau$, а разложение $-\log(2-e^\tau)=\tau+\tau^2+O(\tau^3)$ дает асимптотику. Оценка 2τ верна при любом τ: по пункту (б) $\|\log(\mathbf{Q}e^{\mathbf{S}}\mathbf{Q}^\top)\|_F=\|\mathbf{x}_S\|_2\leqslant\tau$, а $\|\mathbf{Q}\mathbf{S}\mathbf{Q}^\top\|_F\leqslant\|\mathbf{S}\|_F=\tau$. При диагональной $\mathbf{M}$ по пункту (а) $\mathbf{Q}=\mathbf{E}_S^\top$, поэтому $\mathbf{Q}\mathbf{S}\mathbf{Q}^\top=\mathbf{S}_S$ и $\operatorname{vec}_{\sqrt{2}}\mathbf{S}_S=\mathbf{P}_S\operatorname{vec}_{\sqrt{2}}\mathbf{S}=\mathbf{P}_S\mathbf{x}$. Обоснуем оценку члена второго порядка из замечания о консервативности оценки (7): разложение $\log(\mathbf{I}+\mathbf{D})$ до второго порядка дает член $\frac12\mathbf{Q}\mathbf{S}(\mathbf{I}-\mathbf{H})\mathbf{S}\mathbf{Q}^\top$ с $\mathbf{H}=\mathbf{Q}^\top\mathbf{Q}$; в базисе, в котором $\mathbf{H}$ есть проектор на первые m координат, запишем $\mathbf{S}$ блоками с внедиагональным блоком $\mathbf{B}$, тогда этот член равен $\frac12\mathbf{B}\mathbf{B}^\top$, и $\|\frac12\mathbf{B}\mathbf{B}^\top\|_F\leqslant\frac12\|\mathbf{B}\|_F^2\leqslant\frac14\|\mathbf{S}\|_F^2$. □

A.2 Доказательство теоремы 1

При фиксированных данных и окне $\mathbf{X}$ векторы $\mathbf{f}_k=f(\mathbf{X};\boldsymbol{\theta}_k)$ независимы, одинаково распределены, имеют среднее $\bar f(\mathbf{X})$ и средний квадрат отклонения $V(\mathbf{X})$.

(а) Для любого $\mathbf{e}_y$ выполнено $\|F_K-\mathbf{e}_y\|_2^2=\|\bar f-\mathbf{e}_y\|_2^2+2\langle F_K-\bar f,\bar f-\mathbf{e}_y\rangle+\|F_K-\bar f\|_2^2$. Среднее второго слагаемого по параметрам равно нулю, а среднее третьего в

силу независимости равно $K^{-2}\sum_{k,k'}\mathbb{E}\langle \mathbf{f}_k-\bar f,\mathbf{f}_{k'}-\bar f\rangle = V(\mathbf{X})/K$. Параметр принимает конечное число значений, поэтому среднее по параметрам есть конечная сумма, и усреднение по $(\mathbf{X},y)\sim P$ дает (8).

(б) Для $K\geqslant 2$ обозначим через $F_{K-1}^{(-j)}$ среднее $K-1$ векторов $\mathbf{f}_k$, $k\neq j$. Тогда $F_K = K^{-1}\sum_{j=1}^{K} F_{K-1}^{(-j)}$, и по выпуклости $\mathcal{L}(F_K,y)\leqslant K^{-1}\sum_j \mathcal{L}(F_{K-1}^{(-j)},y)$. Каждое $F_{K-1}^{(-j)}$ распределено как F_{K-1}, поэтому после усреднения $\mathbb{E}\mathcal{L}(F_K,y)\leqslant \mathbb{E}\mathcal{L}(F_{K-1},y)$. По неравенству Йенсена $\mathbb{E}\mathcal{L}(F_K,y)\geqslant \mathcal{L}(\mathbb{E}F_K,y)=\mathcal{L}(\bar f,y)$. Если $\mathcal{L}$ непрерывна и ограничена на Δ_L, то $F_K\to\bar f$ почти наверное по усиленному закону больших чисел, и сходимость рисков следует из теоремы Лебега о мажорируемой сходимости.

(в) Пусть $c^*=\hat y_\infty(\mathbf{X})$. Если $\hat y_K(\mathbf{X})\neq c^*$, то существует $c\neq c^*$ с $F_{K,c}\geqslant F_{K,c^*}$. Для фиксированного c величины $Z_k = f_{k,c^*}-f_{k,c}\in[-1,1]$ независимы и имеют среднее $\bar f_{c^*}-\bar f_c\geqslant\gamma(\mathbf{X})$, и по неравенству Хёфдинга $\mathbb{P}\big(K^{-1}\sum_k Z_k\leqslant 0\big)\leqslant \exp\big(-2K\gamma^2/2^2\big) = e^{-K\gamma^2/2}$. Объединение по $L-1$ классам $c\neq c^*$ дает (9); при $\gamma(\mathbf{X})=0$ оценка тривиальна. Индикаторы ошибки F_K и $\bar f$ на окне различаются лишь при $\hat y_K(\mathbf{X})\neq\hat y_\infty(\mathbf{X})$, и усреднение по P дает оценку разности долей ошибок.

(г) Стратифицированный лес равен $F_K^{\mathrm{str}} = B^{-1}\sum_b \mathbf{F}_b$, где $\mathbf{F}_b$ — среднее r независимых деревьев полосы b со средним $\bar f_b$, а $\mathbf{F}_b$ независимы при разных b. Поэтому $\mathbb{E}F_K^{\mathrm{str}} = B^{-1}\sum_b \bar f_b = \bar f$, так как полоса исходного леса равновероятна, и $\mathbb{E}\|F_K^{\mathrm{str}}-\bar f\|_2^2 = B^{-2}\sum_b r^{-1}\mathbb{E}\big[\|f-\bar f_b\|_2^2\,\big|\,b\big] = K^{-1}\big(V(\mathbf{X})-V_B(\mathbf{X})\big)$ по формуле полной дисперсии $V(\mathbf{X}) = B^{-1}\sum_b\mathbb{E}[\|f-\bar f_b\|_2^2\mid b]+V_B(\mathbf{X})$. Остальное повторяет доказательство пункта (а). $\square$

A.3 Доказательство теоремы 2

При фиксированном S величина $k_\cap=|S\cap S'|$ имеет гипергеометрическое распределение: из h элементов, m из которых отмечены, без возвращения выбираются m. Ее факториальные моменты равны $\mathbb{E}k_\cap = m^2/h$ и $\mathbb{E}k_\cap(k_\cap-1) = m^2(m-1)^2/(h(h-1))$: число упорядоченных пар различных элементов S', оба из которых лежат в S, есть сумма индикаторов по $m(m-1)$ упорядоченным парам позиций, и каждый индикатор равен единице с вероятностью $m(m-1)/(h(h-1))$. Отсюда

$$\mathbb{E}N_\cap = \frac{\mathbb{E}k_\cap(k_\cap-1)+2\mathbb{E}k_\cap}{2} = \frac{m^2}{2}\Big(\frac{(m-1)^2}{h(h-1)}+\frac{2}{h}\Big),$$

и деление на $d_m = m(m+1)/2$ дает (11). Подстановка $m=1$ и $m=h$ дает $1/h$ и 1. Канал k лежит в равновероятном S с вероятностью m/h, а пара $\{k,l\}$ — с вероятностью $\binom{h-2}{m-2}/\binom{h}{m}=\varpi_{\mathrm{off}}$; подмножества деревьев независимы, откуда биномиальное распределение числа деревьев, содержащих пару, и ожидаемое число непокрытых пар. Для монотонности обозначим $\psi(m) = m(m-1)^2+2(h-1)m$, так что $\eta_h(m)$ пропорциональна $\psi(m)/(m+1)$. Рассматривая m как вещественную переменную,

$$\psi'(m)(m+1)-\psi(m) = (m-1)^2+2m(m^2-1)+2(h-1)>0 \quad \text{при } m\geqslant 1,$$

так что $\psi(m)/(m+1)$ строго возрастает. Предел при $m=\alpha h+o(h)$ получается делением числителя и знаменателя (11) на h^3. $\square$

A.4 Доказательство теоремы 3

(а) Обозначим через $\mathbf{x}_i$ признаки всех каналов, $\mathbf{P} = \mathbf{P}_S$, а через $\boldsymbol{\Sigma}(\mathbf{q}) = \operatorname{diag}(\mathbf{q}) - \mathbf{q}\mathbf{q}^\top$ матрицу Якоби функции softmax в точке с вероятностями $\mathbf{q}$. Логиты зависят от $\mathbf{b}$ лишь с точностью до общей константы, поэтому нормируем $\sum_c b_c = 0$. Пусть $(\mathbf{W}_\lambda, \mathbf{b}_\lambda)$ — решение задачи (4) для признаков $\mathbf{P}\mathbf{x}_i$; используемые ниже вероятности включения положительны, так как $m \geqslant 2$. Решение существует, поскольку функционал непрерывен и коэрцитивен по $\mathbf{W}$ и по нормированному $\mathbf{b}$: при $b_c \to -\infty$ потеря на окнах класса c неограниченно растет, так как $\pi_c > 0$. Матрица весов единственна в силу строгой выпуклости штрафа. Минимум функции $\mathbf{b} \mapsto \sum_i a_i \ell(y_i, \mathbf{b})$ равен $-\sum_c \pi_c \log \pi_c \leqslant \log L$ и достигается при $\operatorname{softmax}(\mathbf{b}) = \boldsymbol{\pi}$. Так как $\ell \geqslant 0$, сравнение с точкой $(\mathbf{0}, \log \boldsymbol{\pi})$ дает $\lambda \|\mathbf{W}_\lambda\|_F^2 \leqslant \log L$, то есть $\|\mathbf{W}_\lambda\|_F \leqslant \sqrt{\log L / \lambda} \to 0$.

Условие оптимальности по $\mathbf{b}$ есть $\sum_i a_i \operatorname{softmax}(\mathbf{W}_\lambda \mathbf{P}\mathbf{x}_i + \mathbf{b}_\lambda) = \boldsymbol{\pi}$. Векторы $\mathbf{b}_\lambda$ ограничены: если бы разность наибольшей и наименьшей компонент $\mathbf{b}_\lambda$ неограниченно росла вдоль некоторой последовательности, то на подпоследовательности, где номер c наименьшей компоненты постоянен, с учетом $\|\mathbf{W}_\lambda \mathbf{P}\mathbf{x}_i\|_\infty \to 0$ равномерно по i компонента c функции softmax стремилась бы к нулю для всех i, вопреки $\pi_c > 0$. Любая предельная точка $\mathbf{b}_\infty$ удовлетворяет $\operatorname{softmax}(\mathbf{b}_\infty) = \boldsymbol{\pi}$, что вместе с нормировкой определяет ее однозначно, поэтому $\mathbf{b}_\lambda \to \mathbf{b}_\infty = \log \boldsymbol{\pi} - L^{-1} \sum_c \log \pi_c$.

Условие оптимальности по $\mathbf{W}$ есть $\sum_i a_i \big(\operatorname{softmax}(\mathbf{W}_\lambda \mathbf{P}\mathbf{x}_i + \mathbf{b}_\lambda) - \mathbf{e}_{y_i}\big)(\mathbf{P}\mathbf{x}_i)^\top + 2\lambda \mathbf{W}_\lambda = \mathbf{0}$. Поскольку $\operatorname{softmax}(\mathbf{W}_\lambda \mathbf{P}\mathbf{x}_i + \mathbf{b}_\lambda) \to \boldsymbol{\pi}$ для каждого i, получаем $2\lambda \mathbf{W}_\lambda \to \sum_i a_i (\mathbf{e}_{y_i} - \boldsymbol{\pi}) \mathbf{x}_i^\top \mathbf{P}^\top = \mathbf{G}\mathbf{P}^\top$, то есть $\mathbf{W}_\lambda = (2\lambda)^{-1} \mathbf{G}\mathbf{P}^\top + o(\lambda^{-1})$. Столбец $\mathbf{G}\mathbf{P}^\top$, отвечающий координате p дерева, есть столбец p матрицы $\mathbf{G}$ и не зависит от остальных координат.

Осталось найти $\mathbf{b}_\lambda$ в первом порядке. Положим $\boldsymbol{\delta}_\lambda = \mathbf{b}_\lambda - \mathbf{b}_\infty$; сумма компонент этого вектора равна нулю. Разложение softmax в точке $\mathbf{b}_\infty$ в условии оптимальности по $\mathbf{b}$ дает

$$\boldsymbol{\pi} + \boldsymbol{\Sigma}(\boldsymbol{\pi}) \big(\boldsymbol{\delta}_\lambda + \mathbf{W}_\lambda \mathbf{P} \bar{\mathbf{x}}_a\big) + O\big(\|\boldsymbol{\delta}_\lambda\|^2 + \lambda^{-2}\big) = \boldsymbol{\pi}.$$

Матрица $\boldsymbol{\Sigma}(\boldsymbol{\pi})$ переводит вектор из единиц в нуль и невырождена на подпространстве векторов с нулевой суммой, поскольку при $\pi_c > 0$ положительно определена на нем. Проецируя $\mathbf{W}_\lambda \mathbf{P} \bar{\mathbf{x}}_a$ на это подпространство, получаем $\boldsymbol{\delta}_\lambda = -\mathbf{W}_\lambda \mathbf{P} \bar{\mathbf{x}}_a + c'_\lambda \mathbf{1} + O(\|\boldsymbol{\delta}_\lambda\|^2 + \lambda^{-2})$ со скаляром c'_λ. Так как $\boldsymbol{\delta}_\lambda \to \mathbf{0}$, отсюда сначала $\boldsymbol{\delta}_\lambda = O(\lambda^{-1})$, а затем $\boldsymbol{\delta}_\lambda = -\mathbf{W}_\lambda \mathbf{P} \bar{\mathbf{x}}_a + c'_\lambda \mathbf{1} + O(\lambda^{-2})$. Подстановка в $\mathbf{W}_\lambda \mathbf{P}\mathbf{x} + \mathbf{b}_\lambda$ с учетом $\mathbf{W}_\lambda = (2\lambda)^{-1} \mathbf{G}\mathbf{P}^\top + o(\lambda^{-1})$ дает (13); остаток равномерен по $\mathbf{x}$ из ограниченного множества. Строка c матрицы $\mathbf{G}$ равна $\sum_{i:\, y_i = c} a_i \mathbf{x}_i^\top - \pi_c \bar{\mathbf{x}}_a^\top = \pi_c (\boldsymbol{\mu}_c - \bar{\mathbf{x}}_a)^\top$.

(б) Зафиксируем полосу и признаки $\mathbf{x}$ из ограниченного множества. По пункту (а) логиты каждого дерева имеют вид $\mathbf{z}_{\boldsymbol{\theta}} = \log \boldsymbol{\pi} + c_{\boldsymbol{\theta}} \mathbf{1} + \boldsymbol{\delta}_{\boldsymbol{\theta}}$ с $\boldsymbol{\delta}_{\boldsymbol{\theta}} = (2\lambda)^{-1} \mathbf{G}_{\boldsymbol{\beta}} \mathbf{P}_S^\top \mathbf{P}_S (\mathbf{x} - \bar{\mathbf{x}}_a) + o(\lambda^{-1})$, где остаток равномерен по конечному числу значений $\boldsymbol{\theta}$. Функция softmax не меняется при прибавлении кратного вектора из единиц и гладка, поэтому

$$\operatorname{softmax}(\mathbf{z}_{\boldsymbol{\theta}}) = \boldsymbol{\pi} + \boldsymbol{\Sigma}(\boldsymbol{\pi}) \boldsymbol{\delta}_{\boldsymbol{\theta}} + O(\lambda^{-2}).$$

Усреднение по $\boldsymbol{\theta}$ дает $\bar{f} = \boldsymbol{\pi} + \boldsymbol{\Sigma}(\boldsymbol{\pi}) \mathbb{E}_{\boldsymbol{\theta}} \boldsymbol{\delta}_{\boldsymbol{\theta}} + O(\lambda^{-2}) = \operatorname{softmax}(\log \boldsymbol{\pi} + \mathbb{E}_{\boldsymbol{\theta}} \boldsymbol{\delta}_{\boldsymbol{\theta}}) + O(\lambda^{-2})$. Среднее логитов равно $\log \boldsymbol{\pi} + \bar{c}\mathbf{1} + \mathbb{E}_{\boldsymbol{\theta}} \boldsymbol{\delta}_{\boldsymbol{\theta}}$, так что лес с усреднением логитов имеет тот

же выход с точностью до $O(\lambda^{-2})$. Поскольку S и $\boldsymbol{\beta}$ независимы, $\mathbb{E}_{\boldsymbol{\theta}}\mathbf{G}_{\boldsymbol{\beta}}\mathbf{P}_S^\top\mathbf{P}_S = \bar{\mathbf{G}}\boldsymbol{\Pi}$, что дает (14). Матрица $\mathbf{P}_S^\top\mathbf{P}_S$ диагональна с единицами на позициях координат пар каналов из S, и ее среднее есть диагональная матрица вероятностей включения, вычисленных в теореме 2. Для структурированной регрессии сделаем замену $\mathbf{W} = \mathbf{V}\boldsymbol{\Pi}^{1/2}$: штраф становится равным $\lambda\|\mathbf{V}\|_F^2$, а логиты $\mathbf{W}\mathbf{x} = \mathbf{V}\boldsymbol{\Pi}^{1/2}\mathbf{x}$ совпадают с логитами задачи (4) для признаков $\boldsymbol{\Pi}^{1/2}\mathbf{x}$ при $\mathbf{P}_S = \mathbf{I}$. Пункт (а), примененный к этим признакам, дает логиты $\log\boldsymbol{\pi} + c\mathbf{1} + (2\lambda)^{-1}\mathbf{G}\boldsymbol{\Pi}^{1/2}\boldsymbol{\Pi}^{1/2}(\mathbf{x} - \bar{\mathbf{x}}_a) + o(\lambda^{-1})$, которые при сформулированных условиях совпадают с логитами в (14).

(в) При $L = 2$ по пункту (а) разность логитов двух классов дерева с точностью до константы и $o(\lambda^{-1})$ пропорциональна $\langle\mathbf{P}_S\mathbf{g}, \mathbf{P}_S\mathbf{x}\rangle = \sum_{p\in S} g_p x_p = u_S$, где сумма берется по координатам дерева, а $\mathbf{g}$ одна и та же для двух деревьев в силу общих полосы и бутстреп-выборки. Обозначим через g^2 общее значение g_p^2. Для подмножеств, не зависящих от шума, $\mathrm{Cov}_{\boldsymbol{\varepsilon}}(u_S, u_{S'}) = \sigma^2\sum_{p\in S\cap S'} g_p^2 = \sigma^2 g^2 N_\cap$ и $\mathrm{Var}_{\boldsymbol{\varepsilon}}(u_S) = \sigma^2 g^2 d_m$, где пересечение понимается по координатам. Отношение средних по S, S' равно $\mathbb{E}N_\cap/d_m = \eta_h(m)$ по теореме 2. Для среднего K деревьев

$$\mathbb{E}_{S_1,\dots,S_K}\mathrm{Var}_{\boldsymbol{\varepsilon}}\Big(\frac{1}{K}\sum_k u_{S_k}\Big) = \frac{1}{K^2}\Big(K\,\sigma^2 g^2 d_m + K(K-1)\,\sigma^2 g^2\,\mathbb{E}N_\cap\Big)$$
$$= \sigma^2 g^2 d_m\Big(\frac{1}{K} + \frac{K-1}{K}\,\eta_h(m)\Big),$$

что дает второе тождество в (15).

Достаточные условия пункта (б). Если у каждого испытуемого N/n окон, то $\sum_j \beta_{s(j)} = (N/n)\sum_s \beta_s = N$ и $a_i = \beta_{s(i)}/N$ с $\mathbb{E}a_i = 1/N$. Если, кроме того, классы сбалансированы внутри каждого испытуемого, то $\pi_c = 1/L$ для любой бутстреп-выборки, $\mathbf{G}_{\boldsymbol{\beta}} = \sum_i a_i(\mathbf{e}_{y_i} - \boldsymbol{\pi})\mathbf{x}_i^\top$ линейна по $\boldsymbol{\beta}$, и $\bar{\mathbf{G}}$ есть матрица (12) с весами $1/N$. Если средние признаки всех испытуемых совпадают, то $\bar{\mathbf{x}}_a$ одинаково для всех бутстреп-выборок. □

A.5 Доказательство предложения 2

(а) Для фиксированного дерева событие $\beta_{k,s} = 0$ означает, что ни одно из n независимых равновероятных извлечений не попало в s, и имеет вероятность $q_n = (1 - 1/n)^n$; деревья независимы, откуда $|\mathcal{K}_s| \sim \mathrm{Bin}(K, q_n)$. Функция $x\log(1 - 1/x)$ возрастает при $x > 1$: ее производная $\log(1 - 1/x) + 1/(x - 1) = -\log\big(1 + 1/(x - 1)\big) + 1/(x - 1)$ положительна, поскольку $\log(1 + u) < u$ при $u > 0$, а при $x \to \infty$ функция стремится к -1. Поэтому $q_2 = 1/4 \leqslant q_n < e^{-1}$ и $\mathbb{P}(\mathcal{K}_s = \varnothing) = (1 - q_n)^K \leqslant (3/4)^K$.

(б) Параметры деревьев независимы от данных и друг от друга, поэтому при условии $|\mathcal{K}_s| = k$ параметры деревьев из $\mathcal{K}_s$ независимы и распределены как $\boldsymbol{\theta}$ при условии $\beta_s = 0$. При этом условии (b, S) сохраняют распределение, а $\boldsymbol{\beta}$ имеет полиномиальное распределение с n испытаниями и равными вероятностями по $n - 1$ испытуемым, отличным от s, поскольку условное распределение полиномиального вектора при нулевой компоненте получается перенормировкой остальных вероятностей. По условию

дерево с $\beta_s = 0$ есть функция своего параметра и данных $\mathcal{Z}_{-s}$ остальных испытуемых, которые не зависят от $\mathcal{Z}_s$ и состоят из $n-1$ независимых одинаково распределенных испытуемых. Следовательно, при условии $|\mathcal{K}_s| = k$ выход $F^{(-s)}$ не зависит от $\mathcal{Z}_s$ и имеет указанное распределение, а $\mathcal{Z}_s$ играет роль нового испытуемого, что дает (16).

(в) Для каждого окна нового испытуемого ожидаемая потеря леса из k деревьев при фиксированных данных не возрастает по k и не меньше потери бесконечного леса по пункту (б) теоремы 1; оба свойства сохраняются при усреднении по окнам испытуемого и по данным. □

Список литературы

[1] Fabien Lotte. Signal processing approaches to minimize or suppress calibration time in oscillatory activity-based brain–computer interfaces. *Proceedings of the IEEE*, 103(6):871–890, 2015. doi: 10.1109/JPROC.2015.2404941.

[2] Dongrui Wu, Yifan Xu, and Bao-Liang Lu. Transfer learning for EEG-based brain–computer interfaces: a review of progress made since 2016. *IEEE Transactions on Cognitive and Developmental Systems*, 14(1):4–19, 2022. doi: 10.1109/TCDS.2020.3007453.

[3] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Riemannian geometry applied to BCI classification. In *Latent Variable Analysis and Signal Separation (LVA/ICA 2010)*, volume 6365 of *Lecture Notes in Computer Science*, pages 629–636, Berlin, Heidelberg, 2010. Springer. doi: 10.1007/978-3-642-15995-4_78.

[4] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Multiclass brain–computer interface classification by Riemannian geometry. *IEEE Transactions on Biomedical Engineering*, 59(4):920–928, 2012. doi: 10.1109/TBME.2011.2172210.

[5] Marco Congedo, Alexandre Barachant, and Rajendra Bhatia. Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review. *Brain-Computer Interfaces*, 4(3): 155–174, 2017. doi: 10.1080/2326263X.2017.1297192.

[6] Florian Yger, Maxime Berar, and Fabien Lotte. Riemannian approaches in brain-computer interfaces: a review. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 25(10):1753–1762, 2017. doi: 10.1109/TNSRE.2016.2627016.

[7] Fabien Lotte, Laurent Bougrain, Andrzej Cichocki, Maureen Clerc, Marco Congedo, Alain Rakotomamonjy, and Florian Yger. A review of classification algorithms for EEG-based brain–computer interfaces: a 10 year update. *Journal of Neural Engineering*, 15(3):031005, 2018. doi: 10.1088/1741-2552/aab2f2.

[8] Sylvain Chevallier, Igor Carrara, Bruno Aristimunha, Pierre Guetschel, Sara Sedlar, Bruna Lopes, Sébastien Velut, Salim Khazem, and Thomas Moreau. The largest EEG-based BCI reproducibility study for open science: the MOABB benchmark, 2024.

[9] Paolo Zanini, Marco Congedo, Christian Jutten, Salem Said, and Yannick Berthoumieu. Transfer learning: a Riemannian geometry framework with applications to brain–computer

interfaces. *IEEE Transactions on Biomedical Engineering*, 65(5):1107–1116, 2018. doi: 10.1109/TBME.2017.2742541.

[10] Д. Д. Дорин. Явные оценки для касательных признаков ковариационных матриц многомерных временных рядов. Рукопись, 2026.

[11] Alexandre Barachant, Rafal Cycon, and Cédric Gouy-Pailler. BCI Challenge @ NER 2015: code and documentation for the winning solution. GitHub repository, 2015. URL https://github.com/alexandrebarachant/bci-challenge-ner-2015.

[12] Alexandre Barachant. Winning solution of the Decoding Brain Signals Cortana challenge. GitHub repository, 2016. URL https://github.com/alexandrebarachant/decoding-brain-challenge-2016.

[13] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.

[14] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Common spatial pattern revisited by Riemannian geometry. In *2010 IEEE International Workshop on Multimedia Signal Processing (MMSP)*, pages 472–476. IEEE, 2010. doi: 10.1109/MMSP.2010.5662067.

[15] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. BCI signal classification using a Riemannian-based kernel. In *Proceedings of the 20th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN 2012)*, pages 97–102, Bruges, Belgium, 2012. URL https://hal.science/hal-00693321.

[16] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Classification of covariance matrices using a Riemannian-based kernel for BCI applications. *Neurocomputing*, 112:172–178, 2013. doi: 10.1016/j.neucom.2012.12.039.

[17] Alexandre Barachant and Stéphane Bonnet. Channel selection procedure using Riemannian distance for BCI applications. In *2011 5th International IEEE/EMBS Conference on Neural Engineering (NER)*, pages 348–351. IEEE, 2011. doi: 10.1109/NER.2011.5910558.

[18] Alexandre Barachant and Marco Congedo. A Plug&Play P300 BCI using information geometry, 2014. URL https://arxiv.org/abs/1409.0107.

[19] Alexandre Barachant, Anton Andreev, and Marco Congedo. The Riemannian potato: an automatic and adaptive artifact detection method for online experiments using Riemannian geometry. In *Proceedings of the TOBI Workshop IV*, pages 19–20, Sion, Switzerland, 2013.

[20] Emmanuel K. Kalunga, Sylvain Chevallier, Quentin Barthélemy, Karim Djouani, Eric Monacelli, and Yskandar Hamam. Online SSVEP-based BCI using Riemannian geometry. *Neurocomputing*, 191:55–68, 2016. doi: 10.1016/j.neucom.2016.01.007.

[21] Vinay Jayaram and Alexandre Barachant. MOABB: trustworthy algorithm benchmarking for BCIs. *Journal of Neural Engineering*, 15(6):066011, 2018. doi: 10.1088/1741-2552/aadea0.

[22] Alexandre Barachant, Quentin Barthélemy, Gabriel Wagner vom Berg, Alexandre Gramfort, Sylvain Chevallier, Jean-Rémi King, Pedro L. C. Rodrigues, et al. pyRiemann: machine learning for multivariate data with Riemannian geometry, 2026. URL https://github.com/pyRiemann/pyRiemann.

[23] Pedro Luiz Coelho Rodrigues, Christian Jutten, and Marco Congedo. Riemannian Procrustes analysis: transfer learning for brain–computer interfaces. *IEEE Transactions on Biomedical Engineering*, 66(8):2390–2401, 2019. doi: 10.1109/TBME.2018.2889705.

[24] He He and Dongrui Wu. Transfer learning for brain–computer interfaces: a Euclidean space data alignment approach. *IEEE Transactions on Biomedical Engineering*, 67(2):399–410, 2020. doi: 10.1109/TBME.2019.2913914.

[25] Or Yair, Mirela Ben-Chen, and Ronen Talmon. Parallel transport on the cone manifold of SPD matrices for domain adaptation. *IEEE Transactions on Signal Processing*, 67(7): 1797–1811, 2019. doi: 10.1109/TSP.2019.2894801.

[26] Alexandre Bleuzé, Jérémie Mattout, and Marco Congedo. Tangent space alignment: transfer learning for brain-computer interface. *Frontiers in Human Neuroscience*, 16:1049985, 2022. doi: 10.3389/fnhum.2022.1049985.

[27] Satyam Kumar, Florian Yger, and Fabien Lotte. Towards adaptive classification using Riemannian geometry approaches in brain-computer interfaces. In *2019 7th International Winter Conference on Brain-Computer Interface (BCI)*, pages 1–6. IEEE, 2019. doi: 10.1109/IWW-BCI.2019.8737349.

[28] Siamac Fazli, Florin Popescu, Márton Danóczy, Benjamin Blankertz, Klaus-Robert Müller, and Cristian Grozea. Subject-independent mental state classification in single trials. *Neural Networks*, 22(9):1305–1312, 2009. doi: 10.1016/j.neunet.2009.06.003.

[29] Leo Breiman. Bagging predictors. *Machine Learning*, 24(2):123–140, 1996. doi: 10.1007/BF00058655.

[30] Tin Kam Ho. The random subspace method for constructing decision forests. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(8):832–844, 1998. doi: 10.1109/34.709601.

[31] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Series in Statistics. Springer, New York, 2 edition, 2009. doi: 10.1007/978-0-387-84858-7.

[32] Anders Krogh and Jesper Vedelsby. Neural network ensembles, cross validation, and active learning. In *Advances in Neural Information Processing Systems 7 (NIPS 1994)*, pages 231–238. MIT Press, 1995. URL https://proceedings.neurips.cc/paper/1994/hash/b8c37e33defde51cf91e1e03e51657da-Abstract.html.

[33] Gavin Brown, Jeremy Wyatt, Rachel Harris, and Xin Yao. Diversity creation methods: a survey and categorisation. *Information Fusion*, 6(1):5–20, 2005. doi: 10.1016/j.inffus.2004.04.004.

[34] Miles E. Lopes. Estimating the algorithmic variance of randomized ensembles via the bootstrap. *The Annals of Statistics*, 47(2):1088–1112, 2019. doi: 10.1214/18-AOS1707.

[35] Philipp Probst and Anne-Laure Boulesteix. To tune or not to tune the number of trees in random forest. *Journal of Machine Learning Research*, 18(181):1–18, 2018. URL https://jmlr.org/papers/v18/17-269.html.

[36] Lucas Mentch and Siyu Zhou. Randomization as regularization: a degrees of freedom explanation for random forest success. *Journal of Machine Learning Research*, 21(171):1–36, 2020. URL https://jmlr.org/papers/v21/19-905.html.

[37] Daniel LeJeune, Hamid Javadi, and Richard G. Baraniuk. The implicit regularization of ordinary least squares ensembles. In *Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS 2020)*, volume 108 of *Proceedings of Machine Learning Research*, pages 3525–3535, 2020. URL https://proceedings.mlr.press/v108/lejeune20b.html.

[38] Timothy I. Cannings and Richard J. Samworth. Random-projection ensemble classification. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 79(4):959–1035, 2017. doi: 10.1111/rssb.12228.

[39] Leo Breiman. Out-of-bag estimation. Technical report, Department of Statistics, University of California, Berkeley, 1996. URL https://www.stat.berkeley.edu/~breiman/OOBestimation.pdf.

[40] Yuliya V. Karpievitch, Elizabeth G. Hill, Anthony P. Leclerc, Alan R. Dabney, and Jonas S. Almeida. An introspective comparison of random forest-based classifiers for the analysis of cluster-correlated data by way of RF++. *PLoS ONE*, 4(9):e7087, 2009. doi: 10.1371/journal.pone.0007087.

[41] Sohrab Saeb, Luca Lonini, Arun Jayaraman, David C. Mohr, and Konrad P. Kording. The need to approximate the use-case in clinical machine learning. *GigaScience*, 6(5):gix019, 2017. doi: 10.1093/gigascience/gix019.

[42] Shiliang Sun, Changshui Zhang, and Yue Lu. The random electrode selection ensemble for EEG signal classification. *Pattern Recognition*, 41(5):1663–1675, 2008. doi: 10.1016/j.patcog.2007.10.023.

[43] Alain Rakotomamonjy and Vincent Guigue. BCI Competition III: dataset II – ensemble of SVMs for BCI P300 speller. *IEEE Transactions on Biomedical Engineering*, 55(3):1147–1154, 2008. doi: 10.1109/TBME.2008.915728.

[44] Kai Keng Ang, Zheng Yang Chin, Haihong Zhang, and Cuntai Guan. Filter bank common spatial pattern (FBCSP) in brain-computer interface. In *2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence)*, pages 2390–2397. IEEE, 2008. doi: 10.1109/IJCNN.2008.4634130.

[45] Claudia Sannelli, Carmen Vidaurre, Klaus-Robert Müller, and Benjamin Blankertz. Ensembles of adaptive spatial filters increase BCI performance: an online evaluation. *Journal of Neural Engineering*, 13(4):046003, 2016. doi: 10.1088/1741-2560/13/4/046003.

[46] Marie-Constance Corsi, Sylvain Chevallier, Fabrizio De Vico Fallani, and Florian Yger. Functional connectivity ensemble method to enhance BCI performance (FUCONE). *IEEE Transactions on Biomedical Engineering*, 69(9):2826–2838, 2022. doi: 10.1109/TBME.2022.3154885.

[47] Dominik Krzemiński, Sebastian Michelmann, Matthias Treder, and Lorena Santamaria. Classification of P300 component using a Riemannian ensemble approach. In *XV Mediterranean Conference on Medical and Biological Engineering and Computing – MEDICON 2019*, IFMBE Proceedings, pages 1885–1889. Springer, Cham, 2020. doi: 10.1007/978-3-030-31635-8_229.

[48] Lincong Pan, Kun Wang, Lichao Xu, Xinwei Sun, Weibo Yi, Minpeng Xu, and Dong Ming. Riemannian geometric and ensemble learning for decoding cross-session motor imagery electroencephalography signals. *Journal of Neural Engineering*, 20(6):066011, 2023. doi: 10.1088/1741-2552/ad0a01.

[49] Quentin Barthélemy, Louis Mayaud, David Ojeda, and Marco Congedo. The Riemannian potato field: a tool for online signal quality index of EEG. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 27(2):244–255, 2019. doi: 10.1109/TNSRE.2019.2893113.

[50] Alexandre Barachant and Rafal Cycon. Grasp-and-Lift EEG Detection: code and documentation for the winning solution. GitHub repository, 2015. URL https://github.com/alexandrebarachant/Grasp-and-lift-EEG-challenge.

[51] Mehrtash Harandi, Mathieu Salzmann, and Richard Hartley. Dimensionality reduction on SPD manifolds: the emergence of geometry-aware methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(1):48–62, 2018. doi: 10.1109/TPAMI.2017.2655048.

[52] Vincent Arsigny, Pierre Fillard, Xavier Pennec, and Nicholas Ayache. Geometric means in a novel vector space structure on symmetric positive-definite matrices. *SIAM Journal on Matrix Analysis and Applications*, 29(1):328–347, 2007. doi: 10.1137/050637996.

[53] Pauline Dreyer, Manon Bourdil, Loic Bechon, Simon Kojima, Sebastien Velut, Sebastien Rimbert, Raphaëlle Roy, and Fabien Lotte. PROTEUS BCI Bordeaux — EEG/EMG foundation challenge 2026, track 02, 2026. URL https://doi.org/10.82901/nemar.nm000290.

[54] The neural interface foundation challenge, NeurIPS 2026 competition. https://neural-interfaces26.github.io/, 2026. Репозиторий соревнования: https://github.com/neural-interfaces26/2026-competition.

[55] Yilun Chen, Ami Wiesel, Yonina C. Eldar, and Alfred O. Hero. Shrinkage algorithms for MMSE covariance estimation. *IEEE Transactions on Signal Processing*, 58(10):5016–5029, 2010. doi: 10.1109/TSP.2010.2053029.

A Riemannian Forest: Ensembles of Tangent-Space Classifiers on Random Channel Subsets for Cross-Subject Decoding

D. D. Dorin[1]

[1]Moscow Institute of Physics and Technology
E-mail: dorin.dd@phystech.edu

Abstract. Ensembles of tangent-space classifiers trained on subsets of channels and of training subjects have won brain–computer interface competitions, but there is no theory of such ensembles. We call such an ensemble a Riemannian forest. Each of its members, called a tree by analogy with the random forest, receives a random frequency band, a random subset of channels and a bootstrap sample of subjects, recenters the principal submatrices of the covariances at the reference point of the session and fits a logistic regression to their tangent features; the forest averages the class probabilities. Passing to the whitened submatrix of a tree is proved to increase neither geodesic distances nor the spectral spread, so the explicit bounds for tangent features proved earlier hold for every tree. The excess quadratic risk of a finite forest over the infinite one equals the mean variance of the trees divided by their number. The share of tangent coordinates common to two trees is found in closed form. Under strong regularization and balanced data the forest coincides to first order with one logistic regression that penalizes the couplings between channels more strongly than the powers of the channels, and in an isotropic model the correlation of two trees equals the share of common coordinates. The out-of-bag error over subjects estimates the error on a new subject without retraining. The results give rules for choosing the subset size and the number of trees. A synthetic experiment confirms the predicted correlation of trees and variance of the forest, and on public electroencephalographic recordings the forest is better on average than a single tangent-space classifier, although the difference is comparable to the standard deviation over subjects.

Keywords: symmetric positive definite matrices; tangent space; random forest; random subspace method; bagging; brain–computer interface; cross-subject transfer